

Artificial Intelligence Project

Analisi sulle abitudini di consumo del tabacco tra giovani studenti

Leonardo Dessì[0001141270]

Francesco Corigliano[0001137793]

Corso di laurea magistrale in Informatica

Alma Mater Studiorum
Università di Bologna

Maggio, 2024

Indice

Indice **1**

1 Introduzione . . . 2
2 Raccolta dei dati . . . 3
3 Pre-elaborazione dei dati . . . 5
4 Analisi dei dati . . . 8
4.1 Analisi univariata . . . 8
4.2 Analisi multivariata . . . 10
5 Implementazione del modello . . . 18
5.1 Setup . . . 19
5.2 Preparazione dei dati . . . 20
5.3 Calcolo dei pesi per le classi . . . 21
5.4 Training . . . 22
5.5 Confronto tra modelli . . . 23
5.6 Ottimizzazione del probability threshold . . . 30
6 Risultati . . . 31
6.1 SHAP value . . . 36
7 Conclusioni . . . 40

Bibliografia **42**

1 | Introduzione

Il fumo, la forma più letale di consumo di tabacco, rappresenta la modalità più pericolosa e letale di utilizzo del tabacco, ed è associato a cinque milioni di decessi su scala globale [7]. Secondo le stime dell'Organizzazione Mondiale della Sanità, circa la metà dei fumatori andrà incontro a un decesso prematuro in conseguenza della persistente abitudine al fumo. Tale pratica è responsabile di un vasto spettro di patologie, fatali e non, che comprendono il cancro ai polmoni, alla laringe, allo stomaco, al fegato, la leucemia, la broncopneumopatia cronica ostruttiva, le malattie cardiovascolari, la demenza vascolare, gli attacchi di asma, la degenerazione maculare e le malattie vascolari periferiche.[7]

L'inizio e il proseguimento del fumo dipendono dal fumo dei genitori, dalla peer pressure, dalla cultura, da fattori genetici e da influenze ambientali [3]. Il fumo tra amici, fratelli, parenti e i conflitti tra genitori e adolescenti, il monitoraggio dei genitori e le discussioni in famiglia sui rischi del fumo sono predittori significativi delle fasi del fumo [3]. Per smettere di fumare si può influenzare il comportamento dei fumatori attraverso istruzione e mass media, limitando l'influenza dei membri della famiglia fumatori, dei modelli di ruolo (fumatori), dell'industria del tabacco, della responsabilizzazione, dell'educazione.

È necessario comprendere tutti i ruoli dei molteplici fattori responsabili dell'iniziazione al fumo e il ruolo delle barriere nella cessazione per sviluppare interventi personalizzati di grande impatto per ridurre il problema del fumo.

L'obiettivo di questo studio è stato quindi quello di **valutare i fattori che portano all'inizio e alla cessazione del fumo** e di esplorare i vari tipi di incentivi necessari per promuovere la cessazione del fumo.

Questo studio si propone di analizzare i fattori associati al consumo di tabacco in particolare tra studenti adolescenti, al fine di comprendere meglio questo fenomeno e informare le politiche di prevenzione.

Lo studio riveste un'importanza significativa in diversi ambiti:

- **Salute pubblica**: Comprendere i fattori associati al consumo di tabacco fornisce informazioni cruciali per le politiche di salute pubblica. Queste politiche mirano a ridurre il consumo di tabacco e migliorare la salute della popolazione nel suo complesso.

- **Prevenzione**: Identificare le caratteristiche demografiche, comportamentali e psicologiche a rischio consente di sviluppare strategie di prevenzione mirate. Queste strategie possono ridurre l'incidenza del consumo di tabacco in specifiche categorie di persone, contribuendo così alla promozione di stili di vita più sani.

Questa indagine si avvarrà dell'analisi dei dati e dell'impiego di metodologie di apprendimento automatico per identificare i fattori associati al consumo di tabacco tra gli studenti adolescenti.

Attraverso un'analisi dei dati dettagliata, si esploreranno informazioni raccolte attraverso questionari, compresi dati demografici, comportamentali e socio-economici, Saranno impiegati approcci statistici e tecniche di visualizzazione dei dati per individuare tendenze, associazioni e modelli rilevanti relativi al consumo di tabacco tra gli studenti.

In aggiunta, si utilizzeranno metodologie di apprendimento automatico al fine di sviluppare modelli predittivi capaci di identificare i principali determinanti del consumo di tabacco tra gli adolescenti. Si adotteranno algoritmi di classificazione per analizzare i dati e identificare le feature più significative correlate al consumo di tabacco, al fine di predire comportamenti futuri in questo contesto.

---

2 | Raccolta dei dati

La raccolta dei dati è avvenuta consultando i dataset pubblicati dal **Global Youth Tobacco Survey**, un questionario dell'OMS [5].

La sorveglianza Global Youth Tobacco Survey (GYTS) è un'indagine globale sull'uso del tabacco tra i giovani che si affianca alle rilevazioni del progetto Health Behaviour in School-aged Children (HBSC), promosso dall'Ufficio regionale per l'Europa dell'OMS, nel monitoraggio dei comportamenti a rischio legati alla salute dei ragazzi giovani. Mentre entrambe le indagini si svolgono ogni 4 anni.

Il monitoraggio dell'uso del tabacco tra i giovani può essere uno strumento utile per guidare l'attuazione e la valutazione di programmi di prevenzione e promozione della salute, nonché per supportare politiche di contrasto al fumo. Per facilitare il confronto dei dati relativi al consumo di tabacco a livello globale, nazionale e regionale, GYTS

utilizza una metodologia standardizzata per la costruzione del campione e per la raccolta e analisi dei dati.

GYTS prevede la somministrazione di un questionario di 80 domande, elaborato da un'équipe multidisciplinare internazionale, a un campione di circa 1500 ragazzi che frequentano la terza classe della scuola secondaria di primo grado e le classi prima e seconda della scuola secondaria di secondo grado. Il questionario viene tradotto nelle lingue dei Paesi partecipanti e adattato alla realtà di ciascun Paese con l'inserimento di domande di interesse specifico. I ragazzi compilano il questionario a scuola, in forma anonima, con il sostegno degli insegnanti. La partecipazione degli studenti è su base volontaria, previo consenso informato dei genitori. L'indagine include anche un questionario rivolto al personale docente sulle questioni legate all'ambiente scolastico.

Metodologia dei questionari somministrati:

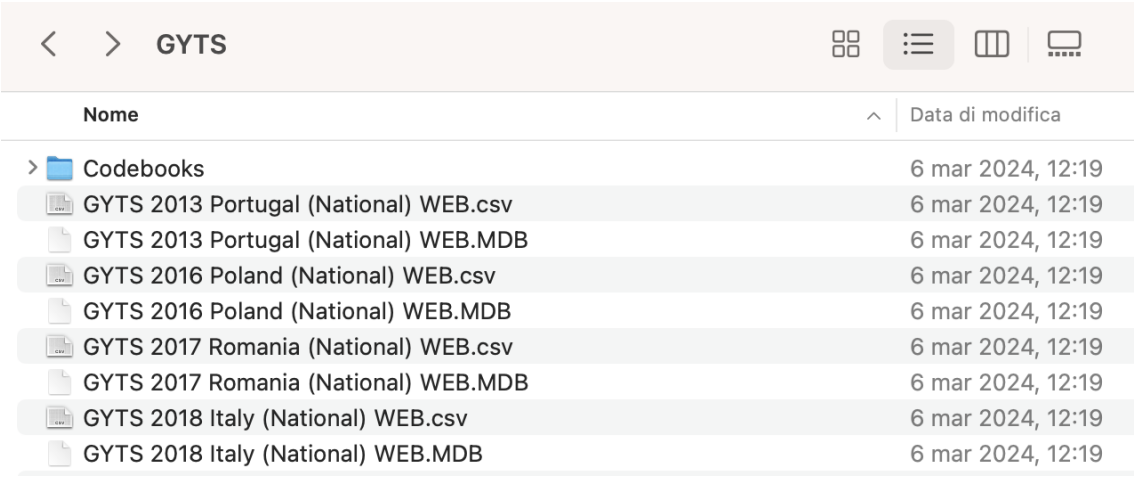
- Progettazione del campione a più stadi con scuole selezionate proporzionalmente alla dimensione dell'iscrizione
- Classi scelte casualmente all'interno delle scuole selezionate
- Questionario auto-somministrato anonimo e confidenziale
- Richiede solo 30-40 minuti per essere somministrato
- **Questionario di base**(insieme standard di domande dell'indagine utilizzato in tutte le località)
- I Paesi possono aggiungere domande al questionario

Le aree indagate da GYTS includono:

- La prevalenza dell'abitudine al fumo di sigaretta e di altri prodotti del tabacco tra i giovani.
- Le conoscenze e attitudini dei ragazzi verso il fumo di sigaretta.
- Il ruolo dei media e della pubblicità sull'uso di sigarette da parte dei giovani.
- L'accessibilità dei prodotti del tabacco.
- L'informazione scolastica sul tabacco.
- L'esposizione al fumo passivo.
- La cessazione dell'abitudine al fumo.

3 | Pre-elaborazione dei dati

Sono stati scelti 4 dataset tra quelli disponibili



Nel processo di pre-elaborazione dei dati, sono state definite alcune funzioni per la lettura dei dataframe, l'identificazione delle colonne comuni (ovvero tutte le domande contenute nel questionario base, che sono presenti nei questionari di ogni paese) e la loro manipolazione per la creazione di un unico dataframe contenente tutti i dati raccolti.

Nel dataset le risposte alle domande del questionario sono rappresentate come valori numerici. Le domande dei questionari che sono state scelte ai fini della ricerca sono le seguenti:

- **Smoke** (`True` / `False`)
  - Rappresenta se soggetto è un fumatore. Questa è la feature che è stata scelta come target per nella nostra ricerca. In particolare è stata ottenuta dalla domanda:

    During the past 30 days (one month), on how many days did you smoke cigarettes?

    Sono state considerate `False` le risposte "*0 days*" mentre sono state considerate come `True` tutte le risposte con un range superiore.
- **State** (Portugal / Poland / Romania / Italy)
  - Rappresenta la nazionalità del soggetto
- **Gender** (Male / Female)

  - Rappresenta il sesso del soggetto.
- **SmokingFriends** (None / Some / Most / All)
  - Rappresenta se il soggetto ha degli amici fumatori.
- **SmokingFather** (`True` / `False`)
  - Rappresenta se il padre del soggetto è un fumatore.
- **SmokingMother** (`True` / `False`)
  - Rappresenta se la madre del soggetto è una fumatrice.
- **WorkingFather** (`True` / `False`)
  - Rappresenta se il padre del soggetto lavora.
- **WorkingMother** (`True` / `False`)
  - Rappresenta se la madre del soggetto lavora.
- **SeenSmokerInSchool** (`True` / `False`)
  - Rappresenta se il soggetto ha visto negli ultimi 30 giorni qualcuno fumare all'interno dell'edificio scolastico o all'esterno della proprietà della scuola (cortile, parco giochi, giardino, parcheggio, ecc.).
- **SeenSmokerInPublicPlace** (0 days / 1 to 2 days / 3 to 4 days / 5 to 6 days / 7 days)
  - Rappresenta il numero di giorni nell'ultima settimana in cui qualcuno ha fumato in presenza del soggetto, in luoghi pubblici all'aperto (parchi giochi, marciapiedi, ingressi di edifici, parchi, spiagge, piscine).
- **SeenSmokerInEnclosedPlace** (0 days / 1 to 2 days / 3 to 4 days / 5 to 6 days / 7 days)
  - Rappresenta il numero di giorni nell'ultima settimana in cui qualcuno ha fumato in presenza del soggetto all'interno di un luogo pubblico al chiuso, diverso da casa sua (come negozi, ristoranti, centri commerciali, cinema).
- **SeenSmokerInHome** (0 days / 1 to 2 days / 3 to 4 days / 5 to 6 days / 7 days)
  - Rappresenta il numero di giorni in cui il soggetto ha visto qualcuno fumare in casa durante l'ultima settimana.
- **ParentWarnings** (`True` / `False`)
  - Rappresenta se qualcuno nella famiglia del soggetto ha discusso con il soggetto degli effetti nocivi del fumo di tabacco?

- **AttractiveSmoker** (More attractive / Less attractive / No difference)
  - Rappresenta se il soggetto pensa che fumare tabacco renda i giovani più o meno attraenti.
- **HardQuitSmoke** (Definitely not / Probably not / Probably yes / Definitely yes)
  - Rappresenta se il soggetto pensa che una volta che qualcuno ha iniziato a fumare tabacco, sia difficile per lui smettere
- **SmokerConfidentInCelebrations** (More comfortable / Less comfortable / No difference)
  - Rappresenta se il soggetto pensa che fumare tabacco aiuti le persone a sentirsi più o meno a proprio agio durante le feste, i party o altri incontri sociali.
- **SchoolWarnings** (Yes / No / I don't know)
  - Rappresenta se al soggetto è stato insegnato il pericolo dell'uso del tabacco durante gli ultimi 12 mesi e durante le lezioni.
- **SeenHealthWarnings** (Yes, but I didn't think much of them / Yes, and they led me to think about quitting smoking or not starting smoking / No)
  - Rappresenta se il soggetto ha visto avvisi riguardo i rischi del consumo di tabacco su confezioni di sigarette negli ultimi 30 giorni
- **AntiTobaccoInEvents** (I did not go to events in the past 30 days/ Yes/No)
  - Rappresenta il soggetto ha visto avvisi riguardo i rischi del consumo di tabacco durante eventi sportivi, concerti, eventi comunitari o incontri sociali negli ultimi 30 giorni
- **AntiTobaccoInMedia** (`True` / `False`)
  - Rappresenta se il soggetto ha visto avvisi riguardo i rischi del consumo di tabacco nei media (televisione, radio, internet, cartelloni pubblicitari, manifesti, giornali, riviste o film) negli ultimi 30 giorni
- **BanTobaccoOutdoors** (`True` / `False`)
  - Rappresenta se il soggetto è a favore del divieto di fumo nelle aree pubbliche all'aperto (campi da gioco, parchi, spiagge, ingresso di edifici, stadio, fermate dell'autobus)
- **HarmfulPassiveSmoke** (Definitely not / Probably not / Probably yes / Definitely yes)
  - Rappresenta se il soggetto pensa che il fumo passivo sia dannoso

Le colonne sono state poi rinominate e i relativi valori mappati con i rispettivi dizionari. Il file contenente i dizionari con il mapping dei valori di tutte le feature selezionate si trova in "**src/scripts/mapping_answers_dict.py**"

Il dataset ottenuto "**data/processed/GYTS_dataset.csv**" comprende risposte demografiche, comportamentali e psicologiche e contiene 20731 righe totali.

---

4 | Analisi dei dati

Nel corso della nostra indagine, abbiamo condotto un'analisi preliminare utilizzando le librerie **Matplotlib** e **Seaborn**. Questa fase è cruciale per comprendere la distribuzione delle variabili, identificare relazioni e individuare eventuali pattern o anomalie nei dati.

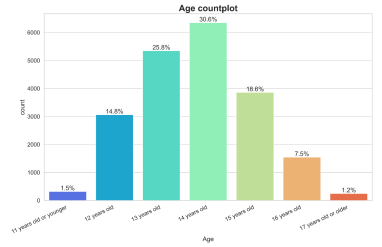
Matplotlib è una libreria Python ampiamente utilizzata per la visualizzazione dei dati, consentendo la creazione di grafici personalizzati per esplorare e rappresentare le informazioni in modo chiaro e efficace.

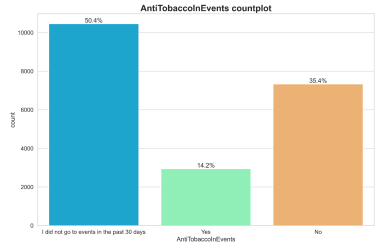
Seaborn, invece, si basa su Matplotlib ed è progettata specificamente per la creazione di grafici statistici informativi, offrendo una sintassi più intuitiva e semplificata. Entrambe le librerie sono strumenti fondamentali per esplorare i dati e comunicare i risultati in modo efficace.

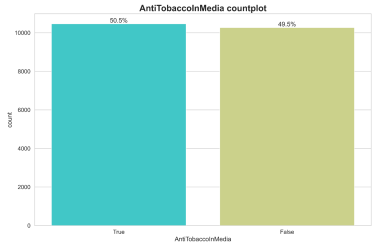
Tutte le analisi sono state condotte nel file Jupyter notebook "**src/data_analysis.ipynb**".

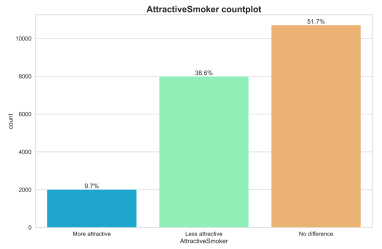
4.1 | Analisi univariata

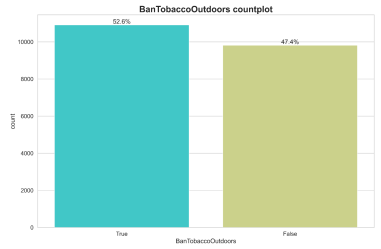
L'analisi univariata fornisce una panoramica dettagliata di una singola variabile all'interno del dataset. Questo approccio aiuta a comprendere la distribuzione, le tendenze e le peculiarità di una variabile senza considerare le relazioni con altre variabili. Nel nostro caso, essendo tutte le variabili categoriche, abbiamo utilizzato un countplot per visualizzare graficamente la distribuzione delle risposte ai questionari per ogni variabile. Questo ci ha permesso di ottenere una panoramica chiara e dettagliata delle singole variabili nel nostro dataset.

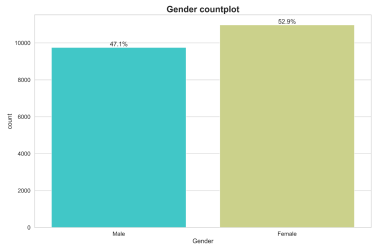

Age countplot
30.6%
25.8%
18.6%
14.8%
7.5%
1.5%
1.2%
17 years old or younger
12 years old
13 years old
14 years old
15 years old
16 years old
17 years old or older
Age
count

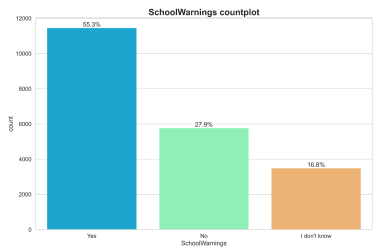

AntiTobaccoInEvents countplot
50.4%
35.4%
14.2%
I did not go to events in the past 30 days
Yes
No
AntiTobaccoInEvents
count

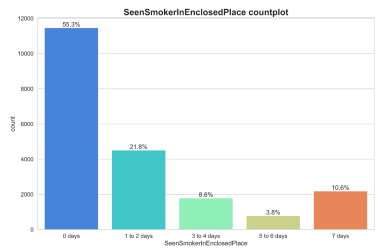

AntiTobaccoInMedia countplot
50.5%
49.5%
True
False
AntiTobaccoInMedia
count

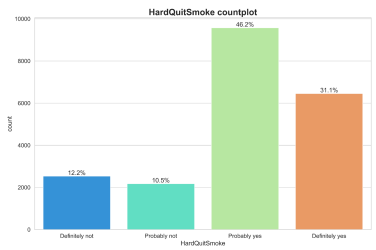

AttractiveSmoker countplot
51.7%
38.6%
9.7%
More attractive
Less attractive
No difference
AttractiveSmoker
count

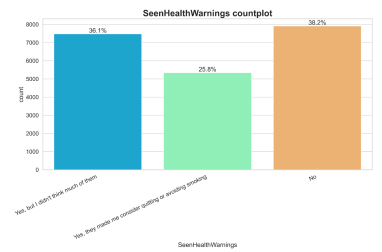

BanTobaccoOutdoors countplot
52.6%
47.4%
True
False
BanTobaccoOutdoors
count

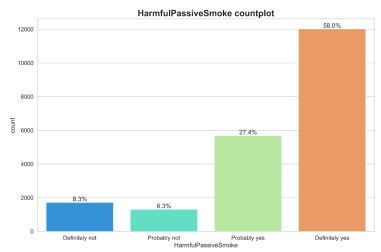

Gender countplot
52.9%
47.1%
Male
Female
Gender
count

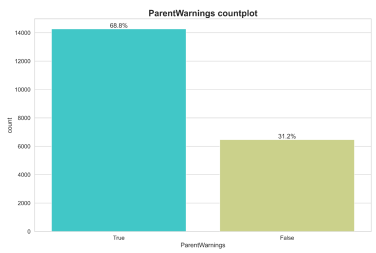

SchoolWarnings countplot
55.3%
27.9%
16.8%
Yes
No
I don't know
SchoolWarnings
count

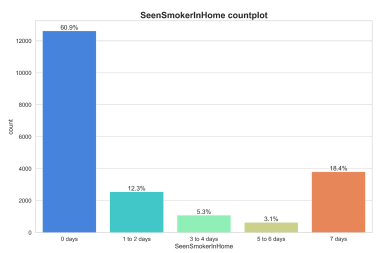

SeenSmokerInEnclosedPlace countplot
55.3%
21.8%
8.6%
3.8%
10.6%
0 days
1 to 2 days
3 to 4 days
5 to 6 days
7 days
SeenSmokerInEnclosedPlace
count

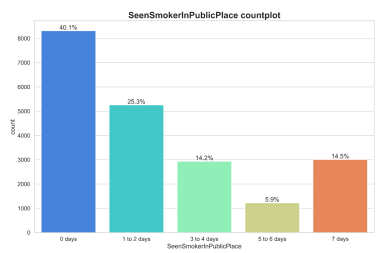

HardQuitSmoke countplot
46.2%
31.1%
12.2%
10.5%
Definitely not
Probably not
Probably yes
Definitely yes
HardQuitSmoke
count

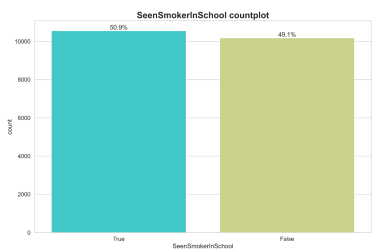

SeenHealthWarnings countplot
38.2%
36.1%
25.8%
Yes, but I don't think much of them
Yes, they made me consider quitting or avoiding smoking
No
SeenHealthWarnings
count

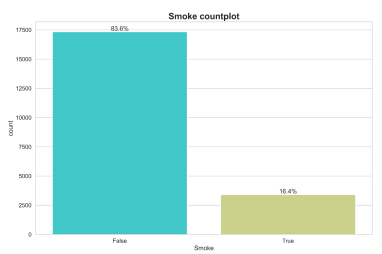

HarmfulPassiveSmoke countplot
58.0%
27.4%
8.3%
6.3%
Definitely not
Probably not
Probably yes
Definitely yes
HarmfulPassiveSmoke
count

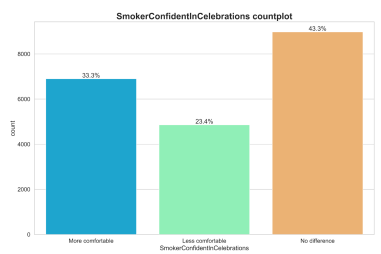

ParentWarnings countplot
68.8%
31.2%
True
False
ParentWarnings
count

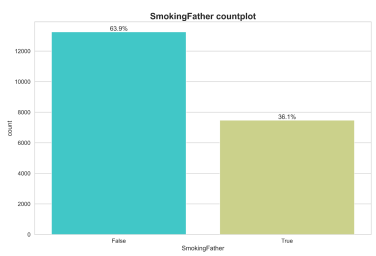

SeenSmokerInHome countplot
60.9%
18.4%
12.3%
5.3%
3.1%
0 days
1 to 2 days
3 to 4 days
5 to 6 days
7 days
SeenSmokerInHome
count

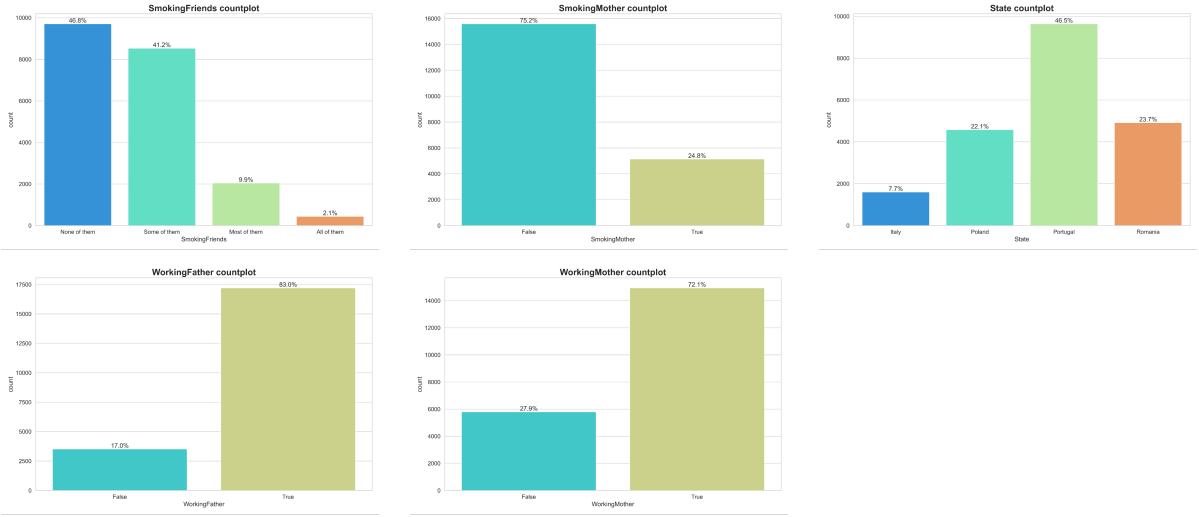

SeenSmokerInPublicPlace countplot
40.1%
26.3%
14.2%
5.9%
14.5%
0 days
1 to 2 days
3 to 4 days
5 to 6 days
7 days
SeenSmokerInPublicPlace
count


SeenSmokerInSchool countplot
50.9%
49.1%
True
False
SeenSmokerInSchool
count


Smoke countplot
83.6%
16.4%
False
True
Smoke
count


SmokerConfidentInCelebrations countplot
43.3%
33.3%
23.4%
More comfortable
Less comfortable
No difference
SmokerConfidentInCelebrations
count

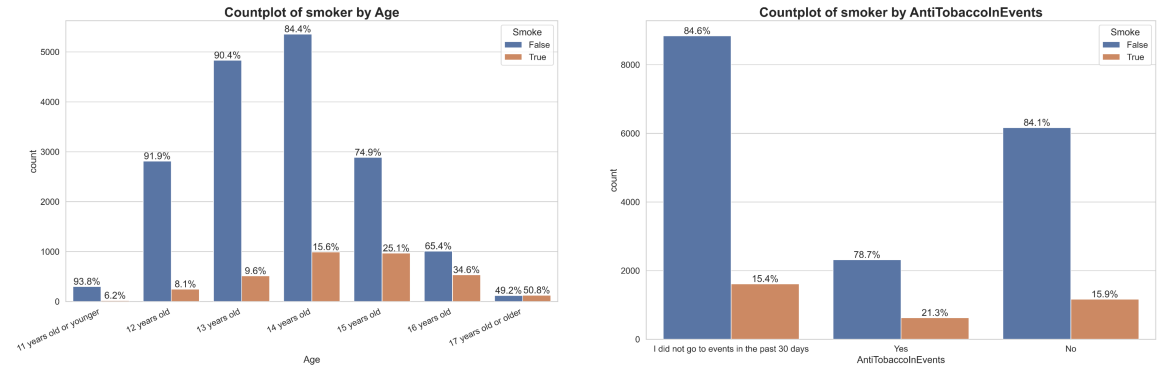

SmokingFather countplot
63.9%
36.1%
False
True
SmokingFather
count

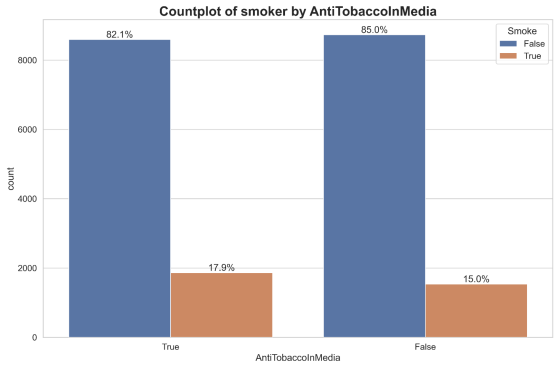


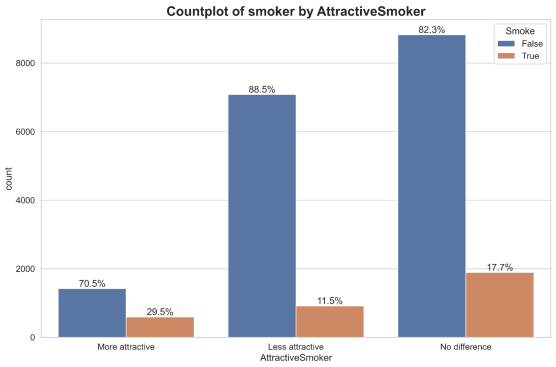
4.2 | Analisi multivariata

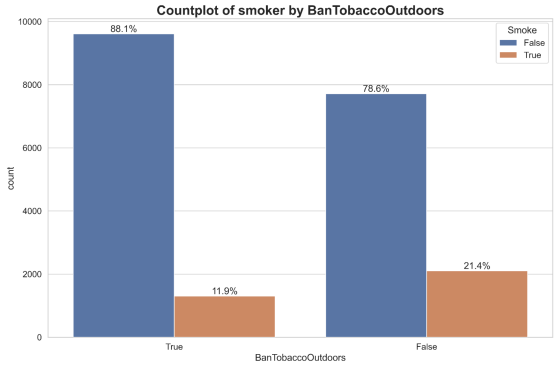
L'analisi multivariata ci permette di esplorare le relazioni e le interazioni tra più variabili nel dataset, fornendoci una visione approfondita dei pattern e delle correlazioni presenti nei dati. Questo approccio è cruciale per identificare i fattori che influenzano la tendenza all'abitudine del consumo di tabacco e ci fornisce un'anteprima delle correlazioni che potremmo sfruttare per sviluppare modelli predittivi accurati e affidabili.

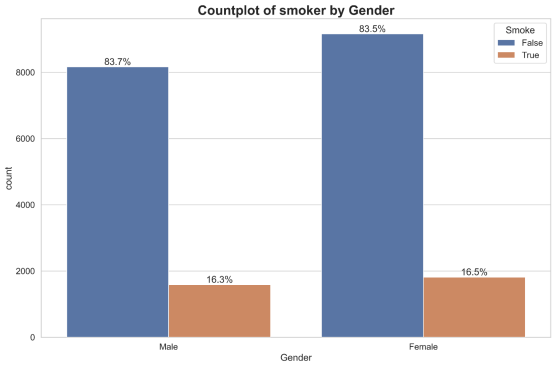
Di seguito sono presenti i grafici che mostrano le relazioni tra la feature "Smoke" e il resto delle variabili.

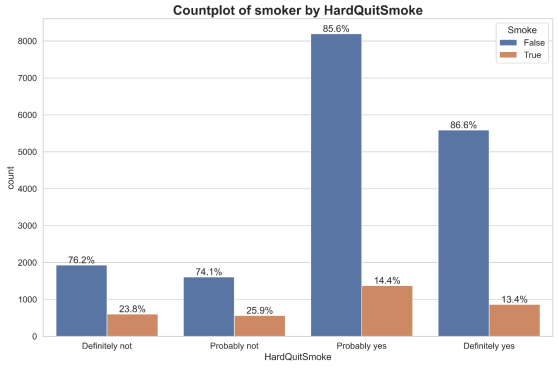


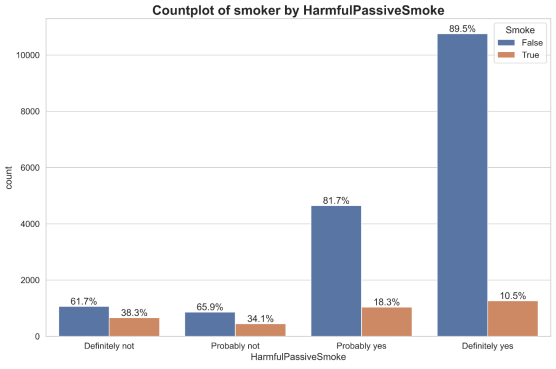

Countplot of smoker by AntiTobaccoInMedia
Smoke
False
True
count
AntiTobaccoInMedia
True
False
82.1%
17.9%
85.0%
15.0%

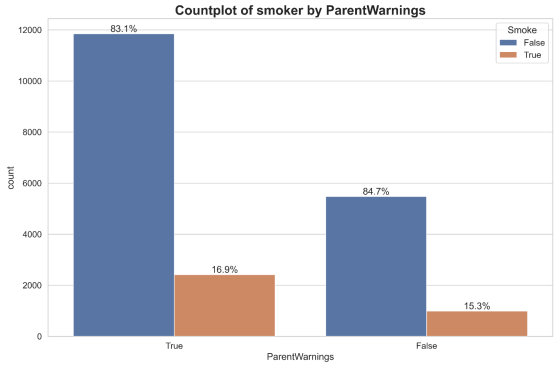

Countplot of smoker by AttractiveSmoker
Smoke
False
True
count
AttractiveSmoker
More attractive
Less attractive
No difference
70.5%
29.5%
88.5%
11.5%
82.3%
17.7%

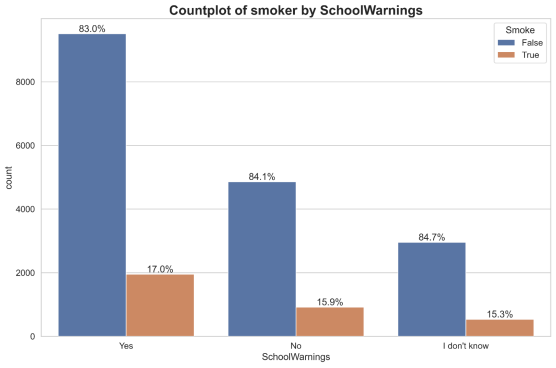

Countplot of smoker by BanTobaccoOutdoors
Smoke
False
True
count
BanTobaccoOutdoors
True
False
88.1%
11.9%
78.6%
21.4%

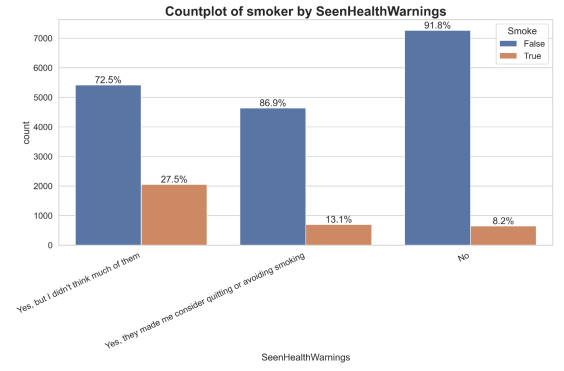

Countplot of smoker by Gender
Smoke
False
True
count
Gender
Male
Female
83.7%
16.3%
83.5%
16.5%

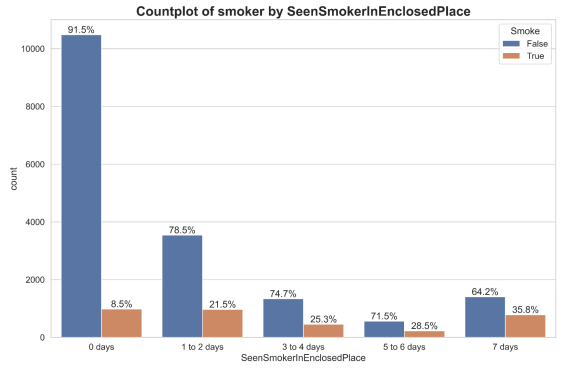

Countplot of smoker by HardQuitSmoke
Smoke
False
True
count
HardQuitSmoke
Definitely not
Probably not
Probably yes
Definitely yes
76.2%
23.8%
74.1%
25.9%
85.6%
14.4%
86.6%
13.4%

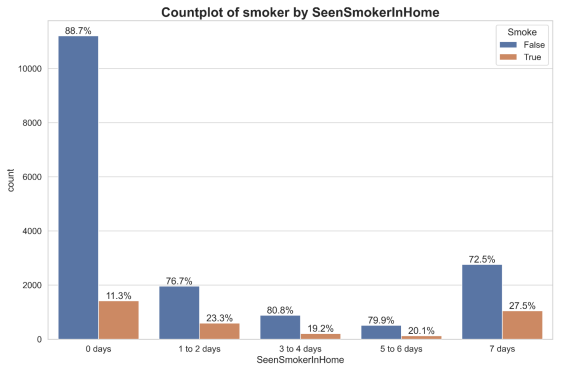

Countplot of smoker by HarmfulPassiveSmoke
Smoke
False
True
count
HarmfulPassiveSmoke
Definitely not
Probably not
Probably yes
Definitely yes
61.7%
38.3%
65.9%
34.1%
81.7%
18.3%
89.5%
10.5%

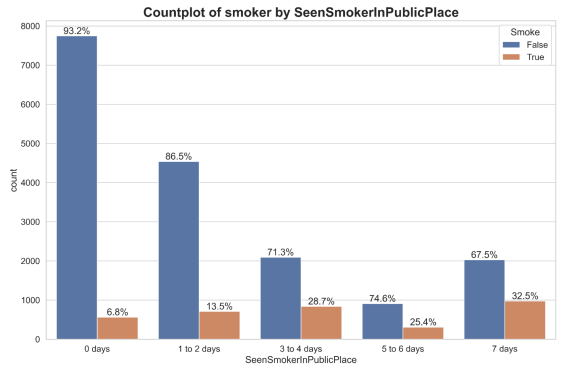

Countplot of smoker by ParentWarnings
Smoke
False
True
count
ParentWarnings
True
False
83.1%
16.9%
84.7%
15.3%

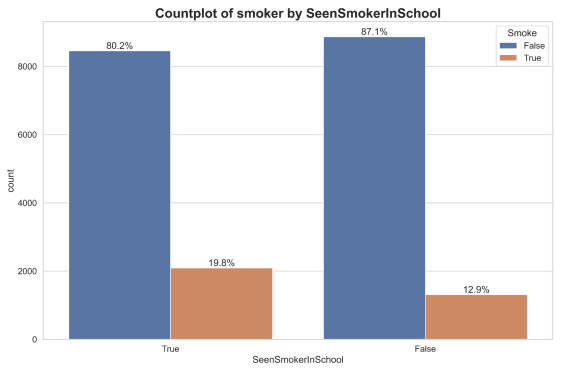

Countplot of smoker by SchoolWarnings
Smoke
False
True
count
SchoolWarnings
Yes
No
I don't know
83.0%
17.0%
84.1%
15.9%
84.7%
15.3%

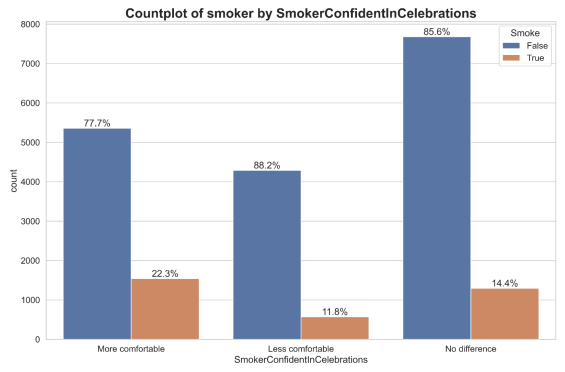

Countplot of smoker by SeenHealthWarnings
Smoke
False
True
count
72.5%
27.5%
86.9%
13.1%
91.8%
8.2%
Yes, but I didn't think much of them
Yes, they made me consider quitting or avoiding smoking
No
SeenHealthWarnings

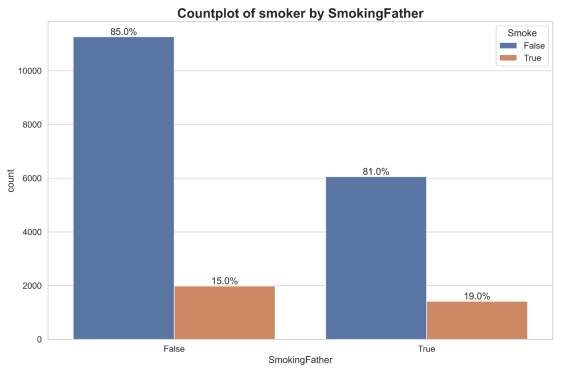

Countplot of smoker by SeenSmokerInEnclosedPlace
Smoke
False
True
count
91.5%
8.5%
78.5%
21.5%
74.7%
25.3%
71.5%
28.5%
64.2%
35.8%
0 days
1 to 2 days
3 to 4 days
5 to 6 days
7 days
SeenSmokerInEnclosedPlace

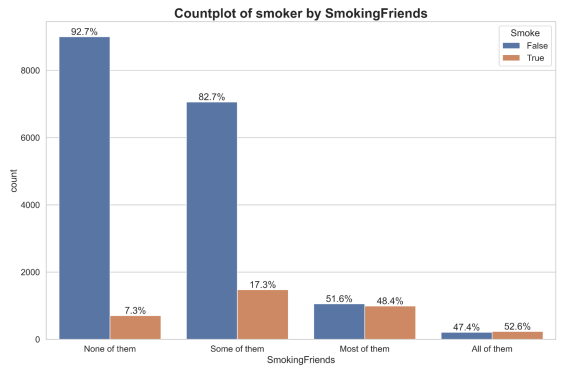

Countplot of smoker by SeenSmokerInHome
Smoke
False
True
count
88.7%
11.3%
76.7%
23.3%
80.8%
19.2%
79.9%
20.1%
72.5%
27.5%
0 days
1 to 2 days
3 to 4 days
5 to 6 days
7 days
SeenSmokerInHome

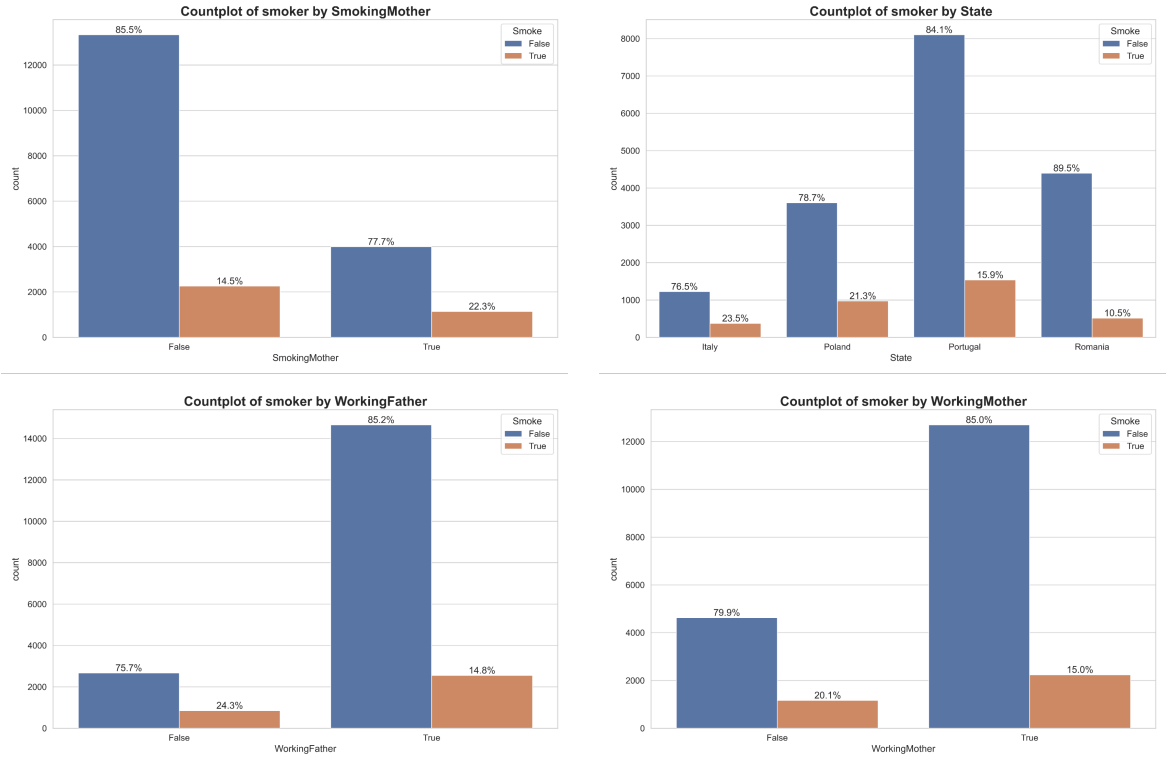

Countplot of smoker by SeenSmokerInPublicPlace
Smoke
False
True
count
93.2%
6.8%
86.5%
13.5%
71.3%
28.7%
74.6%
25.4%
67.5%
32.5%
0 days
1 to 2 days
3 to 4 days
5 to 6 days
7 days
SeenSmokerInPublicPlace


Countplot of smoker by SeenSmokerInSchool
Smoke
False
True
count
80.2%
19.8%
87.1%
12.9%
True
False
SeenSmokerInSchool


Countplot of smoker by SmokerConfidentInCelebrations
Smoke
False
True
count
77.7%
22.3%
88.2%
11.8%
85.6%
14.4%
More comfortable
Less comfortable
No difference
SmokerConfidentInCelebrations


Countplot of smoker by SmokingFather
Smoke
False
True
count
85.0%
15.0%
81.0%
19.0%
False
True
SmokingFather


Countplot of smoker by SmokingFriends
Smoke
False
True
count
92.7%
7.3%
82.7%
17.3%
51.6%
48.4%
47.4%
52.6%
None of them
Some of them
Most of them
All of them
SmokingFriends



Analizzando questi grafici, emerge chiaramente che alcuni fattori esercitano un'influenza significativa sulla propensione di un individuo a fumare. Un esempio lampante si riscontra nel confronto tra le variabili "**Smoke**" e "**SmokingFriends**", dove si osserva una **disparità notevole** nelle percentuali di risposta. È evidente che il 92.7% dei soggetti privi di amici fumatori non sono fumatori, mentre il 52.6% di coloro che hanno tutti gli amici fumatori risultano fumatori. Questi dati rivelano quanto le relazioni sociali possano incidere sulle abitudini dannose. Altre informazioni che si possono ricavare dai grafici sono le seguenti:

- **Età e fumo**: L'incidenza del fumo aumenta con l'età, con una proporzione più alta di fumatori tra i soggetti più anziani. Ad esempio, mentre solo il 6.3% dei soggetti di 11 anni o meno fuma, questa percentuale sale al 25.1% tra i 15enni e al 34.6% tra i 16enni.
- **Genere e fumo**: Non sembra esserci una differenza significativa tra i generi riguardo al fumo. La percentuale di fumatori è simile tra uomini (16.3%) e donne (16.5%).

- **Esposizione al fumo in diversi contesti**: L'esposizione al fumo in diversi contesti, come a scuola, in luoghi pubblici o in luoghi chiusi, sembra essere correlata all'abitudine al fumo. Ad esempio, coloro che hanno visto fumatori in luoghi pubblici per 7 giorni hanno una percentuale di fumatori del 32.5%, rispetto al 6.8% di coloro che non li hanno visti.
- **Influenza dei genitori e situazione lavorativa**: Esiste una relazione tra lo status di fumatore e la situazione lavorativa dei genitori. I figli di genitori fumatori hanno una percentuale più alta di essere fumatori stessi. Inoltre, sembra esserci una leggera tendenza verso una percentuale più alta di fumatori tra i figli di genitori che lavorano rispetto a quelli il cui genitore non lavora.
- **Percezione dei danni del fumo**: Coloro che ritengono che il fumo passivo sia dannoso sembrano essere meno inclini a fumare, con una percentuale di fumatori più bassa tra coloro che ritengono che il fumo passivo sia sicuramente dannoso.

4.2.1 | Association heatmap

Inoltre, è stata creata una tabella di associazione utilizzando il metodo di **Cramér's V** per analizzare ulteriormente le relazioni tra le variabili. Questo ci ha permesso di ottenere una misura quantitativa della forza di associazione tra le variabili, evidenziando relazioni significative.

La tabella di associazione con il metodo di Cramér's V presentata nella Figura 4.1 fornisce un'analisi dettagliata delle relazioni tra le variabili esaminate nello studio sui fattori associati al fumo. Ogni cella della tabella riporta il valore di Cramér's V per la coppia di variabili corrispondenti, offrendo una misura quantitativa della forza di associazione tra esse.

Il valore di Cramér V si calcola come segue:

1. **Creazione della tabella delle frequenze congiunte**: Per prima cosa, si crea una tabella delle frequenze congiunte, che mostra quante volte si verificano le diverse combinazioni di categorie delle due variabili.
2. **Calcolo del Chi-quadro** (χ^2): Il metodo di Cramér's V utilizza il test del chi-quadro per determinare se esiste una relazione significativa tra le variabili. Il test del chi-quadro confronta le frequenze osservate con quelle attese se le due variabili fossero indipendenti. Se il valore del chi-quadro è significativo, ciò suggerisce che le variabili non sono indipendenti.

3. **Normalizzazione del Chi-quadro**: Dopo aver calcolato il chi-quadro, viene normalizzato per tener conto delle dimensioni della tabella e per esprimere la forza della relazione tra le variabili su una scala da 0 a 1.
4. **Calcolo di Cramér's V**: Infine, si calcola il valore di Cramér's V utilizzando la formula:

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(r-1, c-1)}}$$

dove:

- χ^2 è il valore del chi-quadro,
- n è il numero totale di osservazioni nella tabella,
- r è il numero di righe nella tabella,
- c è il numero di colonne nella tabella.

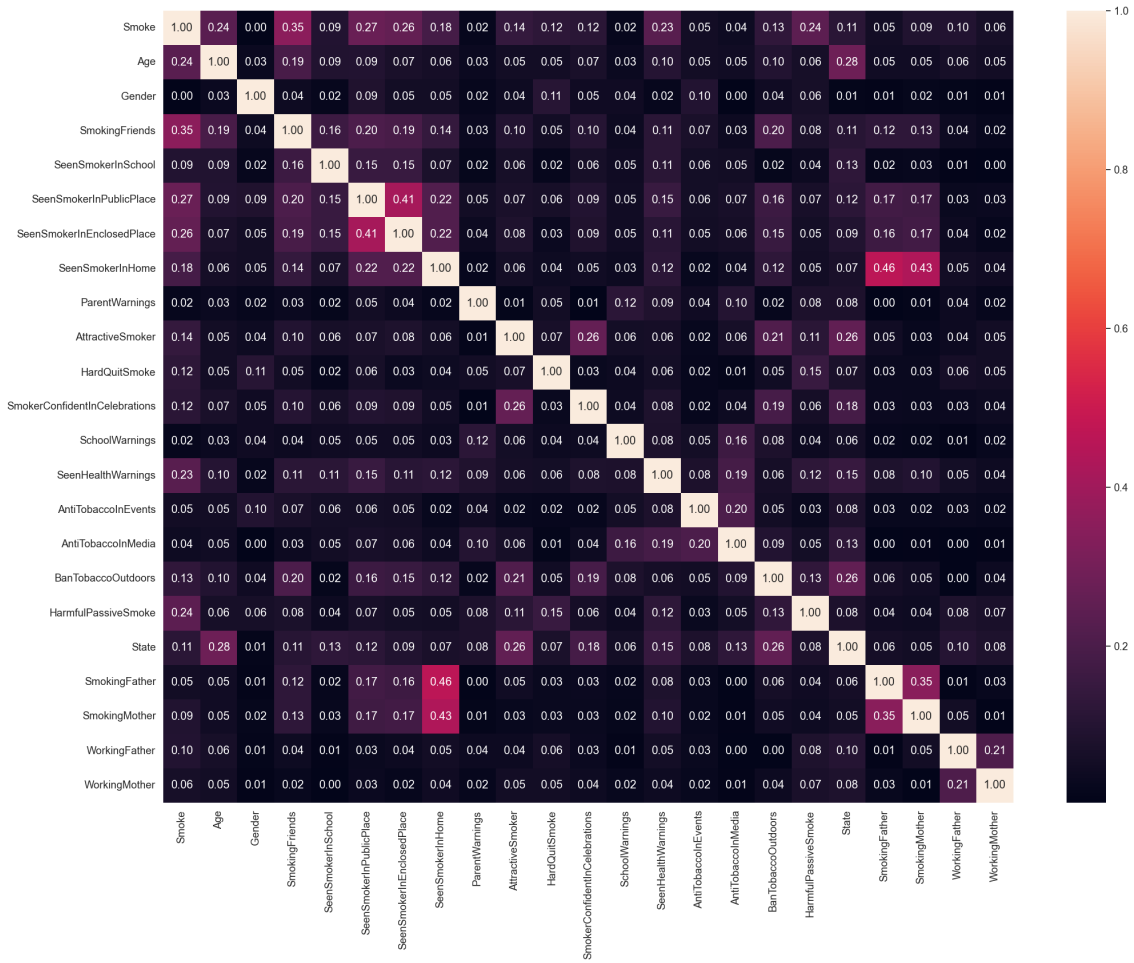


Figura 4.1: Tabella delle associazioni

Il valore di Cramér's V è compreso tra 0 e 1, dove:

- 0 indica l'assenza di associazione tra le variabili
- 1 indica un'associazione perfettamente lineare

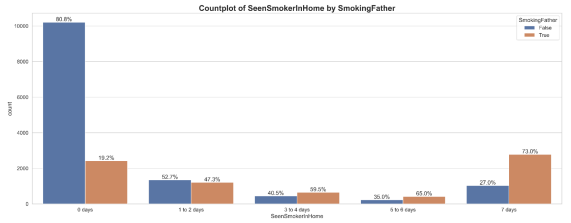
Generalmente, un valore di Cramér's V superiore a 0,20 viene spesso considerato come un'associazione moderata, mentre un valore superiore a 0,30 indica un'associazione forte. Nella seguente tabella è possibile vedere come generalmente viene interpretato il valore V di Cramér.

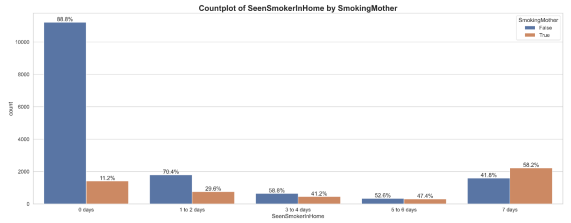
Estimated values	Interpretation of association
0.00–0.10	Negligible
0.10–0.20	Weak
0.20–0.40	Moderate
0.40–0.60	Relatively strong
0.60–0.80	Strong
0.80–1.00	Very strong

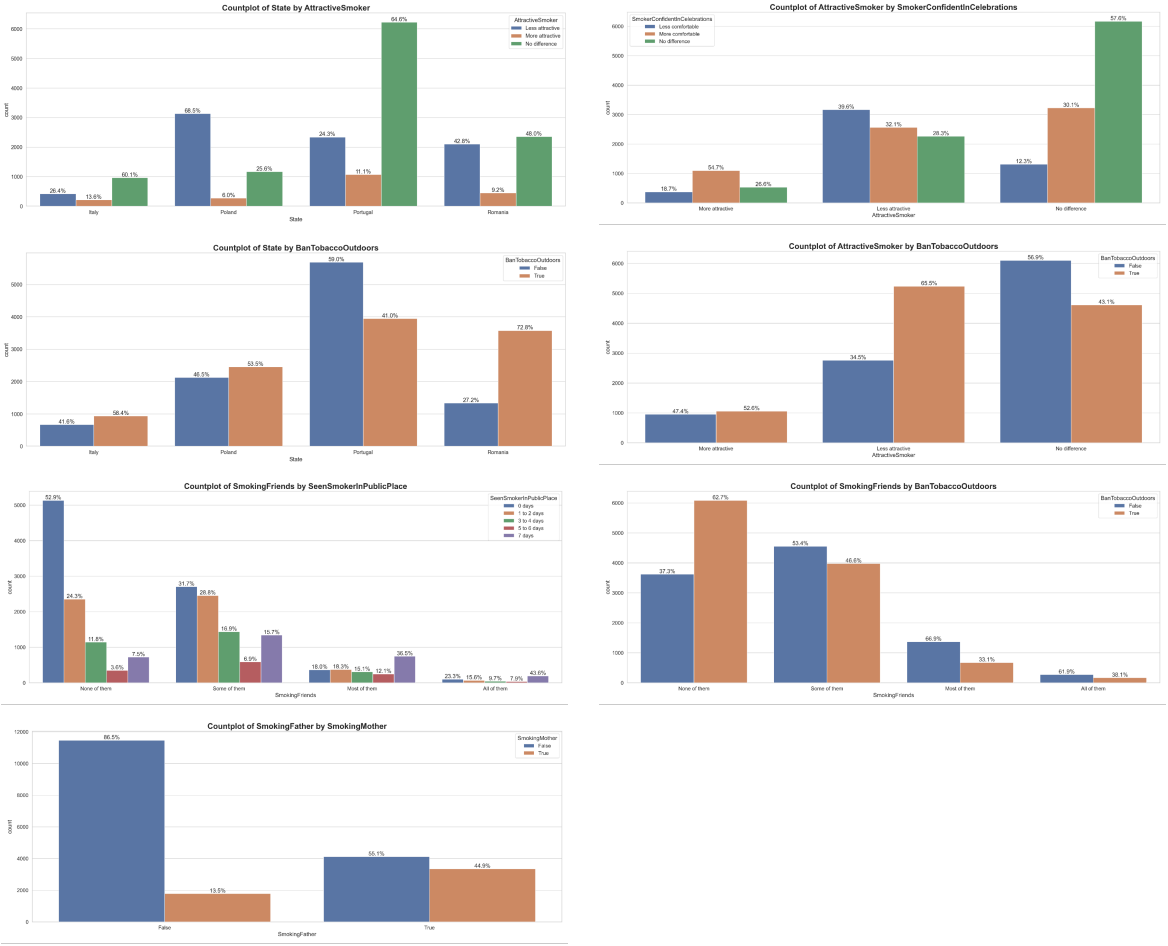
Figura 4.2: Interpretazione del valore V di Cramér[4]

Un valore di Cramér's V più elevato denota una relazione più forte tra le variabili in esame. In questa specifica tabella, i valori di Cramér's V variano da 0.00 a 0.46, suggerendo che alcune variabili sono più strettamente associate al fumo rispetto ad altre.

Relazioni chiave evidenziate dalla tabella Sono state prese in analisi le relazioni particolarmente significative, con un valore V di Cramér superiore a 0.20, ed è stato generato un countplot per le varie relazioni.







Analizzando i grafici correlati ai dati, emergono ulteriori dettagli significativi:

- **Fumo dei genitori** e **esposizione al fumo in casa** (0.46, 0.43): Esiste una correlazione tra il fumo dei genitori e l'osservazione di fumatori in casa. Ad esempio, i figli di genitori fumatori hanno una percentuale più elevata di aver visto fumatori in casa rispetto a quelli con genitori non fumatori.
- **Attrattività dei fumatori** nel **contesto nazionale** (0.26): L'attrattività degli fumatori varia significativamente da paese a paese. In Polonia, ad esempio, il 68.5% degli intervistati trova i fumatori meno attraenti, mentre in Italia solo il 26.4% condivide questa opinione.
- **Percezione di attrattività dei fumatori** e **comfort durante le celebrazioni** (0.26): Esiste una correlazione tra l'attrattività degli fumatori e il livello di comfort percepito durante le celebrazioni. I soggetti che trovano gli fumatori meno attraenti

tendono a credere che fumare in eventi sociali faccia sentire meno a proprio agio chi fuma.

- **Percezione del divieto di fumo all'aperto** e **contesto nazionale**(0.26): La percezione del divieto di fumo all'aperto varia da paese a paese. In Romania, ad esempio, il 72.8% dei soggetti è favorevole al divieto, mentre in Portogallo solo il 41.0% dei soggetti condivide questa posizione.
- **Percezione di attrattività dei fumatori** e **opinione sul divieto di fumo all'aperto** (0.21): La percezione del divieto di fumo all'aperto varia anche in base all'attrattività degli fumatori. Coloro che trovano gli fumatori più attraenti tendono ad essere più contrari al divieto di fumo all'aperto rispetto a coloro che li trovano meno attraenti.
- **Amici fumatori** e **esposizione al fumo in luoghi pubblici** (0.2): Esiste una correlazione tra il tipo di amicizie fumatori e l'osservazione di fumatori in luoghi pubblici. Chi ha tutti gli amici fumatori ha maggiori probabilità di aver visto fumatori in luoghi pubblici per un periodo prolungato.
- **Amici fumatori** e **percezione del divieto di fumo all'aperto** (0.2): La percezione del divieto di fumo all'aperto varia anche in base al gruppo di amicizie. Chi ha tutti gli amici fumatori ha maggiori probabilità di essere contrario al divieto di fumo all'aperto rispetto a chi non ha amici fumatori.

---

5 | Implementazione del modello

L'implementazione del modello predittivo si trova nel file "**src/predictive_model.ipynb**".

La metrica che è stata scelta per valutare il modello è Matthews Correlation Coefficient (MCC).

Il Matthews Correlation Coefficient (MCC) è una misura della qualità delle previsioni binarie, considerando sia i veri positivi che i veri negativi. È particolarmente utile quando le classi sono sbilanciate.

L'MCC viene calcolato come segue:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Dove:

- TP rappresenta i veri positivi (True Positives)
- TN rappresenta i veri negativi (True Negatives)
- FP rappresenta i falsi positivi (False Positives)
- FN rappresenta i falsi negativi (False Negatives)

L'MCC produce un valore compreso tra -1 e +1, dove +1 indica una previsione perfetta, 0 indica una previsione casuale e -1 indica una previsione completamente sbagliata.

Una volta trovato un modello con un buon valore di MCC, ci proponiamo di identificare le **feature più importanti** nella predizione. Questo ci permette di capire quali variabili hanno il maggior impatto nel determinare se un individuo fumi o meno. Identificare le feature più importanti non solo fornisce insight sulle influenze più significative nel comportamento del fumo, ma può anche aiutare a focalizzare gli sforzi di intervento e prevenzione su determinati fattori chiave.

Per l'implementazione, abbiamo utilizzato **PyCaret**, un framework open-source per il machine learning in Python che semplifica il processo di sviluppo dei modelli, fornendo un'interfaccia user-friendly per la preparazione dei dati, la selezione dei modelli, la messa a punto degli iperparametri e la valutazione delle prestazioni del modello.

5.1 | Setup

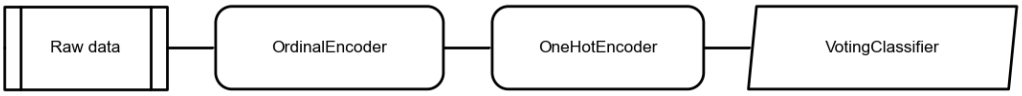
Questa funzione inizializza l'ambiente di addestramento e crea la pipeline di trasformazione. La funzione di setup deve essere chiamata prima di eseguire qualsiasi altra funzione. Richiede due parametri obbligatori: dati e target. Tutti gli altri parametri sono opzionali.

```
setup = pc.setup(data=dataset,
                 target='Smoke',
                 index=False,
                 train_size=0.8,
                 session_id=12,
                 categorical_features=categorical_columns,
                 ordinal_features= ordinal_features,
                 imputation_type=None,
                 max_encoding_ohe=0,
                 encoding_method=OneHotEncoder(dtype=int, sparse_output=False),
                 n_jobs=10
                 )
```

In particolare i parametri più importanti selezionati nel setup sono i seguenti:

- `data`: il nostro dataframe che contiene tutti i dataset uniti e preprocessati.
- `target`: la feature da predire (se il soggetto è fumatore o non fumatore).
- `train_size`: Questo parametro permette di specificare la dimensione del dataset di train rispetto al dataset intero. Nel nostro setup è stato settato 0.8 per usare come set di train l'80% del dataset.
- `session_id`: Questo parametro è il seed utilizzato in tutte le funzioni che usano la generazione di numeri casuali
- `categorical_features`: permette di specificare la lista di feature di tipo categorico.
- `ordinal_features`: Indicare che alcune features sono ordinali consente al modello di comprendere l'ordine intrinseco delle categorie anziché trattarle come variabili categoriche ordinarie, migliorando così l'interpretazione e la qualità delle previsioni.
- `imputation_type`: serve per selezionare il tipo di algoritmo utilizzato per imputare dati quando sono mancanti. Nel nostro dataset non sono presenti informazioni nulle quindi questo parametro è stato utilizzato per disattivare l'imputazione
- `max_encoding_ohe`: Questo parametro viene settato a 0 per poter utilizzare un encoding personalizzato.
- `encoding_method`: Questo è il metodo che verrà usato per codificare le variabili categoriche. Il metodo scelto è il One-Hot Encoding.
- `n_jobs`: permette di specificare il numero di thread da utilizzare nell'addestramento del modello.

5.2 | Preparazione dei dati



Inizialmente, i dati raw sono stati sottoposti a un processo di codifica per renderli adatti all'analisi. Le variabili ordinali sono state trattate utilizzando l'**ordinal encoding**, una tecnica che assegna un numero intero a ciascuna categoria in base al suo ordine di importanza. Questo approccio è particolarmente utile quando le categorie hanno un ordine naturale, come ad esempio nel caso della feature *HarmfulPassiveSmoke*, in cui le risposte sono assolutamente no, probabilmente no, probabilmente sì, sicuramente sì.

Successivamente, le colonne categoriche sono state codificate utilizzando il **one-hot encoding**. Questa tecnica di codifica genera nuove colonne binarie per ciascuna categoria, assegnando il valore 1 alla colonna corrispondente alla categoria presente e 0 alle al-

tre. Questa tecnica è preziosa per variabili in cui non esiste un ordine intrinseco tra le categorie e permette al modello di apprendere in maniera più efficace da tali dati.

Dopo aver completato il processo di codifica, il dataset è stato diviso in due sottoinsiemi: un **train set**, utilizzato per addestrare il modello, e un **test set**, utilizzato per valutare le prestazioni del modello. Questa suddivisione è stata effettuata con una proporzione del 80% per il train set e del 20% per il test set, garantendo una rappresentazione adeguata dei dati in entrambi i set.

Description	Value
Session id	42
Target	Smoke
Target type	Binary
Original data shape	(20731, 23)
Transformed data shape	(20731, 42)
Transformed train set shape	(16584, 42)
Transformed test set shape	(4147, 42)
Ordinal features	6
Numeric features	8
Categorical features	8
Preprocess	True
Imputation type	None
Maximum one-hot encoding	0
Encoding method	OneHotEncoder
Fold Generator	StratifiedKFold
Fold Number	10
CPU Jobs	10

5.3 | Calcolo dei pesi per le classi

Dato il disequilibrio nel dataset (83.6% non fumatori, 16.4% fumatori), è stato necessario calcolare dei pesi da assegnare alle classi. I pesi delle classi attribuiscono una maggiore importanza alle osservazioni della classe meno rappresentata durante il processo di addestramento del modello. Questo permette al modello di dare una priorità adeguata alla corretta classificazione di queste osservazioni, nonostante la loro minor frequenza nel dataset.

La formula usata per calcolare i pesi delle classi è la seguente

$$Class\ Weight = \sqrt{\frac{n_{samples}}{n_{classes} \times n_{samples\ per\ class}}}$$

Dove:

- $n_{samples}$ rappresenta il numero totale di campioni presenti nel dataset.
- $n_{classes}$ indica il numero totale di classi presenti nel problema di classificazione.
- $n_{samples\ per\ class}$ corrisponde al numero di campioni appartenenti alla classe specifica.

5.4 | Training

Una volta completata la preparazione dei dati e calcolati i pesi delle classi, si avvia la fase di training del modello. Per la validazione dei risultati, abbiamo adottato il metodo della **Stratified K-fold Cross Validation**.

Lo stratified k-fold cross validation funziona suddividendo il set di dati in k sottoinsiemi (folds) mantenendo la distribuzione delle classi originale. Esso funziona come segue

1. **Suddivisione dei dati**: Inizialmente, il set di dati viene diviso in k sottoinsiemi uguali mantenendo la distribuzione delle classi. Ciò significa che se ci sono due classi nel set di dati, ogni sottoinsieme avrà approssimativamente la stessa proporzione di campioni di ciascuna classe.

2. **Iterazioni di training e test**: Il modello viene addestrato k volte utilizzando $k-1$ sottoinsiemi come dati di training e il sottoinsieme rimanente come dati di test. Questo processo viene ripetuto k volte, ogni volta utilizzando un sottoinsieme diverso come set di test.

3. **Calcolo delle metriche di valutazione**: Per ogni iterazione, vengono calcolate le metriche di valutazione (come accuratezza, precisione, richiamo, F1-score, ecc.) utilizzando i dati di test. Alla fine delle k iterazioni, le metriche di valutazione vengono generalmente aggregate per fornire una stima delle prestazioni del modello.

Nel nostro caso, abbiamo scelto di utilizzare $k = 10$, il che significa che il training set è stato diviso in 10 fold. Il modello viene quindi addestrato e validato 10 volte, utilizzando ogni volta un fold diverso come set di validation e gli altri come set di training. Questo

processo permette di ottenere 10 valutazioni delle prestazioni del modello, una per ogni fold, che vengono poi combinate per ottenere una stima più affidabile delle performance complessive del modello. Una volta effettuato la cross validation otteniamo una tabella come la seguente che mostra i risultati per ogni fold e a fine tabella è presente la media e la deviazione standard dei risultati.

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Fold							
0	0.8547	0.0000	0.5458	0.5602	0.5529	0.4662	0.4662
1	0.8602	0.0000	0.5788	0.5745	0.5766	0.4929	0.4929
2	0.8632	0.0000	0.6190	0.5788	0.5982	0.5159	0.5163
3	0.8457	0.0000	0.5421	0.5305	0.5362	0.4437	0.4437
4	0.8625	0.0000	0.5404	0.5880	0.5632	0.4818	0.4824
5	0.8565	0.0000	0.5699	0.5616	0.5657	0.4797	0.4797
6	0.8607	0.0000	0.5956	0.5724	0.5838	0.5002	0.5003
7	0.8546	0.0000	0.5956	0.5529	0.5735	0.4860	0.4865
8	0.8540	0.0000	0.5699	0.5536	0.5616	0.4741	0.4741
9	0.8577	0.0000	0.5809	0.5643	0.5725	0.4871	0.4872
Mean	0.8570	0.0000	0.5738	0.5637	0.5684	0.4827	0.4829
Std	0.0049	0.0000	0.0245	0.0153	0.0161	0.0185	0.0186

Una volta completata la fase di training utilizzando lo stratified k-fold cross validation, il modello è pronto per essere valutato sul test set per verificare le sue prestazioni su dati completamente nuovi e non osservati durante il training.

5.5 | Confronto tra modelli

Per effettuare un benchmark e confrontare i vari modelli, abbiamo scelto di utilizzare solo modelli di machine learning che supportano l'utilizzo dei pesi (class weights).

I modelli testati sono:

- Light Gradient Boosting Machine
- Extra Trees Classifier
- Random Forest Classifier
- Ridge Classifier
- Logistic Regression

- SVM - Linear Kernel
- Decision Tree Classifier

È stato prima effettuato un test senza utilizzare i pesi, e i risultati ottenuti nella cross validation sono i seguenti:

Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Light GBM	0.8777	0.0	0.4270	0.7139	0.5340	0.4687	0.4894
Random Forest Classifier	0.8751	0.0	0.3466	0.7642	0.4763	0.4166	0.4591
Extra Trees Classifier	0.8733	0.0	0.3422	0.7515	0.4699	0.4092	0.4504
SVM - Linear Kernel	0.8500	0.0	0.4009	0.5743	0.4587	0.3772	0.3918
Logistic Regression	0.8582	0.0	0.3234	0.6350	0.4282	0.3569	0.3836
Ridge Classifier	0.8532	0.0	0.1957	0.6859	0.3040	0.2495	0.3119
Decision Tree Classifier	0.8013	0.0	0.4486	0.4053	0.4256	0.3059	0.3066

Mentre i risultati ottenuti senza pesi sul test set sono i seguenti:

Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Light GBM	0.8850	0.8808	0.4493	0.7500	0.5620	0.5005	0.5223
Random Forest Classifier	0.8830	0.8670	0.3774	0.8082	0.5145	0.4578	0.5009
Extra Trees Classifier	0.8806	0.8677	0.3612	0.8039	0.4985	0.4416	0.4874
Logistic Regression	0.8671	0.8536	0.3480	0.6890	0.4624	0.3958	0.4260
Ridge Classifier	0.8570	0.5971	0.2100	0.7222	0.3254	0.2715	0.3373
Decision Tree Classifier	0.8109	0.6704	0.4611	0.4295	0.4448	0.3310	0.3313
SVM - Linear Kernel	0.8503	0.5559	0.1175	0.8000	0.2049	0.1700	0.2698

Successivamente sono stati allenati i modelli con i pesi calcolati precedentemente e i risultati della cross validation sono i seguenti:

Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Light GBM	0.8611	0.0	0.5984	0.5745	0.5860	0.5026	0.5029
Random Forest Classifier	0.8759	0.0	0.3454	0.7749	0.4774	0.4186	0.4630
Logistic Regression	0.8454	0.0	0.5793	0.5273	0.5518	0.4587	0.4596
Ridge Classifier	0.8477	0.0	0.5635	0.5352	0.5487	0.4572	0.4576

Extra Trees Classifier	0.8746	0.0	0.3469	0.7606	0.4759	0.4159	0.4576
SVM - Linear Kernel	0.8415	0.0	0.5301	0.5307	0.5192	0.4262	0.4328
Decision Tree Classifier	0.8173	0.0	0.4585	0.4461	0.4518	0.3423	0.3426

Mentre i risultati con i pesi sul test set sono i seguenti:

Model	**Accuracy**	**AUC**	**Recall**	**Prec.**	**F1**	**Kappa**	**MCC**
Light GBM	0.8621	0.8580	0.6035	0.5764	0.5897	0.5068	0.5070
Random Forest Classifier	0.8751	0.8588	0.3568	0.7523	0.4841	0.4231	0.4614
Extra Trees Classifier	0.8744	0.8533	0.3524	0.7500	0.4795	0.4185	0.4572
Logistic Regression	0.8433	0.8413	0.5668	0.5209	0.5429	0.4485	0.4491
Ridge Classifier	0.8442	0.7245	0.5463	0.5247	0.5353	0.4417	0.4419
SVM - Linear Kernel	0.8544	0.6999	0.4699	0.5684	0.5145	0.4297	0.4324
Decision Tree Classifier	0.8119	0.6586	0.4302	0.4277	0.4290	0.3164	0.3164

Analizzando in base all'MCC è stato quindi scelto di utilizzate i pesi. Inoltre sono stati selezionati i 3 modelli con l'MCC più alto nella cross validation e sono stati utilizzati per il modello finale.

I tre modelli migliori che sono stati selezionati sono i seguenti:

1. **Light Gradient Boosting Machine** (LGBM) è un algoritmo di apprendimento automatico basato su gradient boosting framework. È noto per la sua velocità e prestazioni, specialmente su dataset di grandi dimensioni. Utilizza una tecnica di boosting, che combina diverse predizioni deboli (alberi decisionali deboli) per creare un modello più potente. L'allenamento di LGBM coinvolge l'aggiunta sequenziale di alberi di decisione, con ciascun nuovo albero focalizzato sugli errori residui degli alberi precedenti. LGBM è particolarmente efficace nel gestire dataset con molte feature e può gestire dati categorici senza richiedere una loro previa codifica.
2. **Random Forest** è un algoritmo di apprendimento automatico che opera attraverso il concetto di bagging (bootstrap aggregating). Crea un insieme di alberi decisionali durante il processo di addestramento, dove ciascun albero viene allenato su un subset casuale dei dati di addestramento (con sostituzione). Durante la fase di previsione, l'output del Random Forest è la media delle previsioni degli alberi

decisionali (nel caso di regressione) o la modalità delle previsioni (nel caso di classificazione). Questo metodo riduce l'overfitting e migliora la generalizzazione del modello.

3. **Extra Trees**, o **Extremely Randomized Trees**, è una variante del Random Forest. L'idea principale di Extra Trees è simile a quella di Random Forest, ma con una differenza chiave nella scelta dei split. Mentre il Random Forest seleziona i migliori split per ogni nodo da un sottoinsieme casuale delle feature, Extra Trees seleziona casualmente i split per ogni nodo da tutto il set di dati. Questa casualità aggiuntiva può rendere Extra Trees più robusto al rumore e all'overfitting. Poiché ogni albero viene costruito in modo più casuale, l'Extra Trees tende a essere meno computazionalmente costoso rispetto al Random Forest, poiché richiede meno calcoli durante la fase di addestramento.

5.5.1 | Hyperparameter tuning

Dopo aver selezionato i tre modelli, abbiamo proceduto con il tuning dei parametri per massimizzare l'accuracy di ciascun modello.

Il tuning di un modello, consiste nell'ottimizzazione dei parametri del modello. Esso è il processo di regolazione dei parametri di un algoritmo di machine learning per massimizzare le prestazioni del modello sui dati di addestramento. L'obiettivo è trovare la combinazione ottimale di parametri che consenta al modello di generalizzare meglio sui dati non visti e di ottenere prestazioni migliori.

In particolare nel progetto è stata utilizzata l'**ottimizzazione Bayesiana** di scikit-optimize. L'ottimizzazione bayesiana sfrutta l'idea della "funzione surrogata" per individuare il subset ottimale di iperparametri che meglio definiscono il modello.

Inizialmente, si costruisce un modello di probabilità surrogata, che funge da approssimazione della relazione tra gli iperparametri e le prestazioni del modello. Successivamente, si cerca il set di iperparametri che massimizza la funzione surrogata. Una volta individuati questi iperparametri ottimali, che performano bene sulla funzione surrogata, vengono applicati alla nostra funzione obiettivo originale e ne vengono valutati i risultati.

Dopo aver valutato i risultati, si aggiorna il modello di probabilità surrogata in base alle prestazioni ottenute e si ripete il processo per un numero prefissato di iterazioni. Ogni iterazione rende il modello sempre più esperto, imparando dai risultati dei modelli precedenti.

La potenza di questo approccio risiede nel fatto che anziché scegliere casualmente i parametri, la selezione è guidata da un'ottimizzazione informata ed esperienziale, basata su modelli più semplici. Con ogni iterazione, il modello diventa più abile nell'apprendere dalle esperienze passate, conducendo a una selezione più precisa degli iperparametri ottimali.

5.5.2 | Ensembling

Una volta completato il tuning dei parametri per ciascun modello, si è proceduto all'ensembling di ogni modello. L'**ensembling** di un modello è una tecnica che combina diversi modelli di machine learning per migliorare le prestazioni complessive del sistema. In particolare è stato usato il metodo del **Bagging** (Bootstrap Aggregating) per il modello LightGBM e del **Boosting** per il modello Extra Tree e Random Forest.

Il **Bagging** funziona creando diverse repliche del modello base, ognuna addestrata su un sottoinsieme casuale dei dati di addestramento. Questo sottoinsieme viene selezionato tramite il campionamento con sostituzione, noto come bootstrap. In pratica, ciò significa che ogni modello "vede" una versione leggermente diversa del dataset di addestramento.

Dopo aver addestrato tutti i modelli, le loro previsioni vengono combinate per ottenere una previsione finale. Nel nostro caso, ossia un problema di classificazione, viene adottata una strategia di voto o di media delle previsioni dei singoli modelli.

L'idea alla base del Bagging è che, combinando i modelli addestrati su dataset leggermente diversi, si riduce la varianza complessiva del modello, migliorando così la capacità di generalizzazione e riducendo il rischio di overfitting. Inoltre, poiché i modelli sono adde-

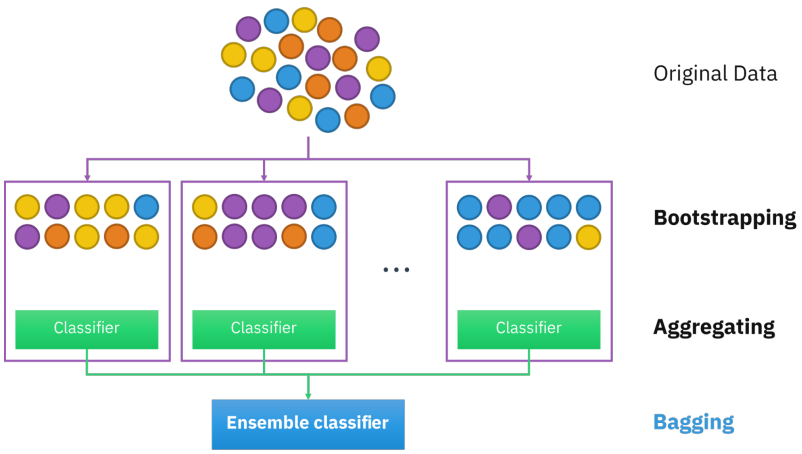


Figura 5.1: Bagging

strati in modo indipendente, il Bagging si presta particolarmente bene a parallelizzare il processo di addestramento, consentendo di ottenere prestazioni elevate anche su dataset di grandi dimensioni.

Invece per quanti riguarda il **Boosting**, i modelli vengono addestrati in sequenza, e ciascun modello successivo si concentra sugli errori compiuti dai modelli precedenti, cercando di correggerli.

Il processo di boosting funziona nel seguente modo: inizialmente, si addestra un modello base su tutto il set di dati. Successivamente, si creano modelli addizionali, ognuno dei quali cerca di migliorare la previsione sui campioni che sono stati classificati erroneamente dai modelli precedenti. Questo processo viene ripetuto iterativamente fino a quando non viene raggiunto un determinato numero di modelli o fino a quando non viene raggiunta una soglia di accuratezza desiderata.

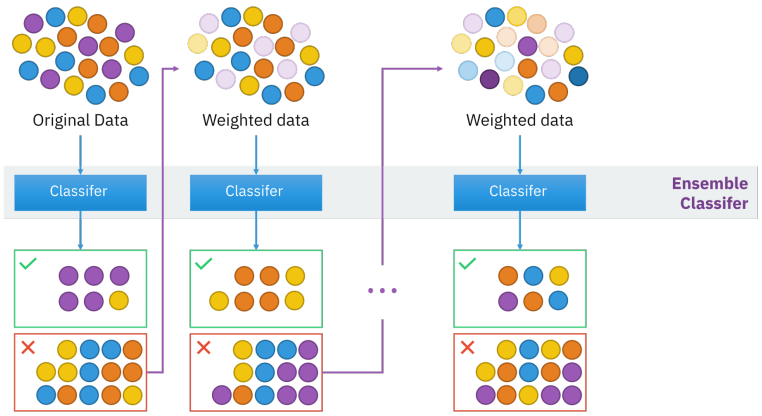


Figura 5.2: Boosting

5.5.3 | Blended model

Dopo aver completato il tuning e l'applicazione della tecnica del bagging su tutti e tre i modelli selezionati, è stato eseguito il blending di LGBM ed Extra Trees in un unico modello utilizzando la tecnica del soft voting. È stato testato il blending anche aggiungendo Random Forest, ottenendo però risultati meno ottimali, quindi è stata scelta la prima configurazione con solo due modelli per proseguire.

Il **blending** è una tecnica di ensemble in cui i risultati di più modelli diversi vengono combinati insieme per ottenere una previsione più accurata. Nel nostro caso, i model-

li precedentemente addestrati sono combinati insieme in modo da sfruttare le forze di ciascun modello e compensare eventuali debolezze.

Il **soft voting** è un metodo di ensemble in cui la previsione finale è ottenuta prendendo la media delle probabilità previste da ciascun modello e scegliendo la classe con la probabilità media più alta. Questo metodo è particolarmente utile quando i modelli di base producono probabilità invece di previsioni dirette.

I risultati della cross validation del blended model sono i seguenti:

	Accuracy	**AUC**	**Recall**	**Prec.**	**F1**	**Kappa**	**MCC**
Fold							
0	0.8686	0.0000	0.5788	0.6054	0.5918	0.5135	0.5137
1	0.8716	0.0000	0.5641	0.6210	0.5912	0.5152	0.5161
2	0.8656	0.0000	0.5568	0.5984	0.5769	0.4971	0.4975
3	0.8734	0.0000	0.6081	0.6171	0.6125	0.5369	0.5369
4	0.8770	0.0000	0.5882	0.6349	0.6107	0.5377	0.5383
5	0.8770	0.0000	0.5404	0.6504	0.5904	0.5187	0.5218
6	0.8522	0.0000	0.5625	0.5484	0.5554	0.4668	0.4668
7	0.8764	0.0000	0.5956	0.6304	0.6125	0.5390	0.5393
8	0.8601	0.0000	0.5551	0.5763	0.5655	0.4822	0.4823
9	0.8697	0.0000	0.5919	0.6053	0.5985	0.5208	0.5208
Mean	0.8692	0.0000	0.5742	0.6088	0.5905	0.5128	0.5134
Std	0.0076	0.0000	0.0204	0.0282	0.0187	0.0230	0.0232

Mentre i risultati del blended model sul test set sono i seguenti

Model	**Accuracy**	**AUC**	**Recall**	**Prec.**	**F1**	**Kappa**	**MCC**
Voting Classifier	0.8695	0.8582	0.5844	0.6067	0.5954	0.5176	0.5178

Questi risultati sono migliori sia rispetto ai risultati della cross validation che ai risultati delle previsioni sul set di test. Questi risultati sono stati ottenuti con il probability threshold di default, che corrisponde a 0.50, quindi successivamente è stata effettuata un'ottimizzazione del threshold per provare a migliorare ulteriormente i risultati.

5.6 | Ottimizzazione del probability threshold

L'**ottimizzazione del probability threshold** è il processo di ricerca del valore ottimale per la soglia di probabilità utilizzata per fare predizioni in un modello di classificazione binaria o multiclasse.

Nei modelli di classificazione, la probabilità di appartenenza di un'istanza a una determinata classe è spesso calcolata come output del modello. Tuttavia, per effettuare una predizione, è necessario definire una soglia di probabilità al di sopra della quale l'istanza viene assegnata a una classe specifica.

L'ottimizzazione del probability threshold coinvolge solitamente i seguenti passaggi:

1. **Definizione della soglia di probabilità di default**: In molti casi, viene utilizzata una soglia di probabilità predefinita (ad esempio 0.5) per fare predizioni. Tuttavia, questa soglia potrebbe non essere ottimale per tutte le situazioni e può essere soggetta a modifiche.
2. **Valutazione delle prestazioni del modello al variare della soglia di probabilità**: Si valutano le prestazioni del modello utilizzando diverse soglie di probabilità. Questo può essere fatto calcolando metriche come precisione, richiamo, F1-score (nel nostro caso è stato usato l'MCC)
3. **Selezione della soglia ottimale**: Si seleziona la soglia di probabilità che massimizza la metrica di interesse o che ottimizza una combinazione di metriche in base alle esigenze specifiche dell'applicazione.
4. **Valutazione delle prestazioni del modello con la soglia ottimale**: Infine, si valutano le prestazioni del modello utilizzando la soglia di probabilità ottimale su un set di dati di test separato per confermare che il modello si comporti bene anche in presenza di dati non osservati durante l'addestramento.

L'ottimizzazione del probability threshold è importante perché può migliorare le prestazioni del modello, specialmente in situazioni in cui le classi sono sbilanciate o quando è necessario un compromesso tra precisione e richiamo.

Nel nostro specifico caso è risultato che il probability threshold ottimale è quello di default, ossia 0.50, come si può vedere dal seguente grafico:

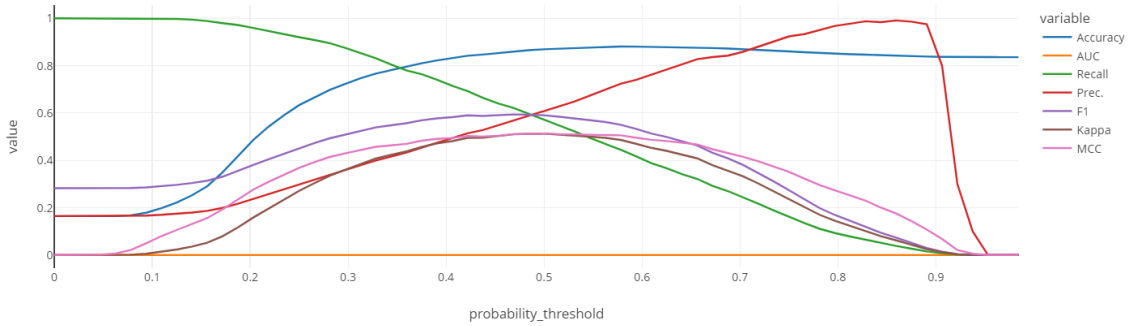


Figura 5.3: Metriche al variare del probability threshold

6 | Risultati

In questa sezione esploreremo i risultati dell'analisi focalizzandoci sulle feature più influenti individuate durante il processo. Questo ci consentirà di ottenere una visione dettagliata dei fattori che possono incidere sul consumo di tabacco tra i giovani.

Nota: *è fortemente consigliato consultare i risultati tramite la Explainer Dashboard, visualizzabile eseguendo l'ultima cella del file notebook Jupyter "predictive_model.ipynb", che permette di visualizzare i risultati e i grafici in modo interattivo. Tutti i risultati seguenti sono stati estrapolati impostando il probability threshold, a 0.50, ovvero il valore che massimizza l'MCC nelle nostre osservazioni e predizioni.*

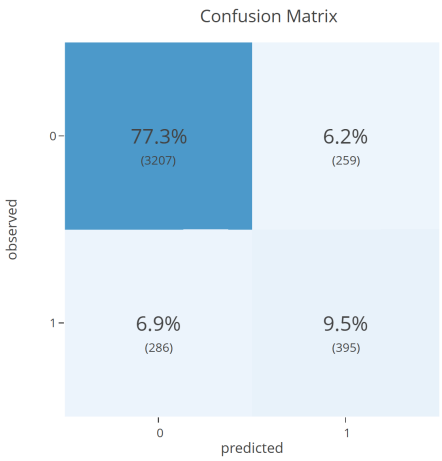


Figura 6.1: Confusion Matrix

La **confusion matrix**, o matrice di confusione, è una tabella utilizzata per valutare le prestazioni di un modello di classificazione. Essa mostra il numero di predizioni corrette e errate fatte dal modello su un set di dati di test, confrontando le predizioni effettuate con le vere etichette di classe dei dati.

La confusion matrix permette di calcolare diverse metriche di valutazione del modello, ad esempio:

- **Accuracy**: La proporzione totale di predizioni corrette rispetto al numero totale di predizioni effettuate dal modello, calcolata come $(TP + TN)/(TP + TN + FP + FN)$.
- **Precision**: La proporzione di istanze predette come positive che sono effettivamente positive, calcolata come $TP/(TP + FP)$.
- **Recall** (o Sensitivity): La proporzione di istanze positive che sono state predette correttamente, calcolata come $TP/(TP + FN)$.
- **F1-score**: La media armonica di precision e recall, che tiene conto sia di falsi positivi che di falsi negativi, calcolata come $2 \cdot (Precision \cdot Recall)/(Precision + Recall)$.

Nel nostro caso le metriche ottenute sono le seguenti:

Metric	Score	Metric	Score
Accuracy	0.852	MCC	0.577
Precision	0.554	Recall	0.794
Roc auc score	0.903	Pr auc score	0.717
F1	0.653	Log loss	0.288

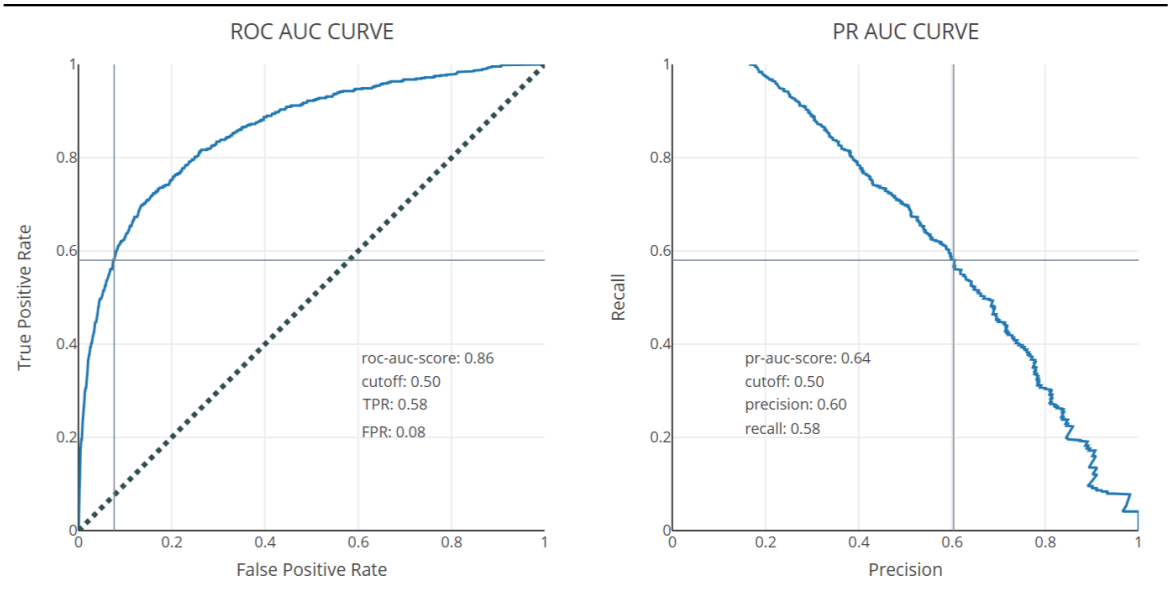
Il grafico ROC (Receiver Operating Characteristic) e il grafico PR (Precision-Recall) sono entrambi strumenti utilizzati per valutare le prestazioni di un modello di classificazione binaria, fornendo una visualizzazione delle sue capacità di discriminazione tra classi positive e negative. Entrambi i grafici sono spesso accompagnati da una misura di prestazione denominata Area Under the Curve (AUC).

- **ROC AUC Curve**: La ROC curve mostra la relazione tra il tasso di veri positivi (True Positive Rate, TPR) e il tasso di falsi positivi (False Positive Rate, FPR) al

variare della soglia di classificazione. Il TPR è plottato sull'asse delle ordinate (y) mentre il FPR è plottato sull'asse delle ascisse (x). Un modello ideale avrà una curva che si avvicina rapidamente all'angolo in alto a sinistra del grafico, indicando un TPR elevato e un FPR basso, mentre un modello casuale produrrà una linea diagonale. L'AUC della ROC curve fornisce una misura della capacità predittiva del modello, dove un valore più vicino a 1 indica un modello migliore.

- **PR AUC Curve**: La PR curve mostra la relazione tra la precisione e il richiamo (o sensitivity) al variare della soglia di classificazione. La precisione è plottata sull'asse delle ascisse (x) mentre il richiamo è plottato sull'asse delle ordinate (y). Un modello ideale avrà una curva che si avvicina rapidamente all'angolo in alto a destra del grafico, indicando una precisione elevata e un richiamo elevato. L'AUC della PR curve fornisce una misura della capacità predittiva del modello in modo simile all'AUC della ROC curve, dove un valore più vicino a 1 indica un modello migliore.

I risultati ottenuti sul set di test sono i seguenti:



Si può notare che l'area sotto la curva(AUC) del primo grafico è dello 0.86 mentre nel grafico di precision-recall è di 0.64.

In figura 6.2 abbiamo un Precision Plot. In questo grafico è possibile vedere la relazione tra la probabilità predetta che un indice appartenga alla classe positiva e la percentuale di

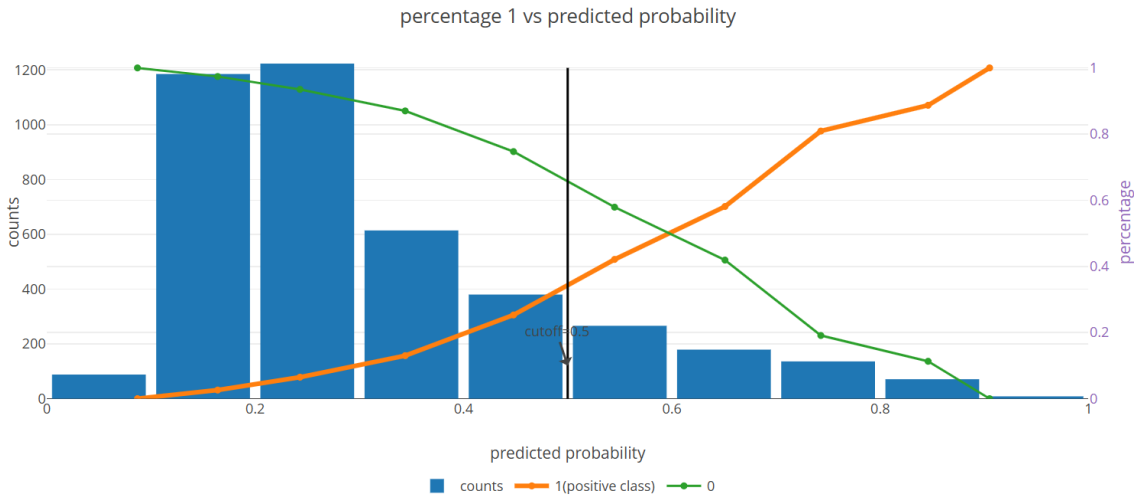


Figura 6.2: Precision plot

indici osservati nella classe positiva. Nel nostro modello viene predetta una probabilità, le osservazioni vengono ordinate in ordine crescente. Poi le osservazioni vengono divise in 10 gruppi.

E ora è stato disegnato un grafico, dove:

- in blu, con un grafico a colonne, viene rappresentato il numero di osservazioni in un dato gruppo.
- in arancione con un grafico a linea viene rappresentato la percentuale di persone in un dato gruppo che sono fumatori
- con un grafico a linea verde viene rappresentata la percentuale di persone che non sono fumatori.

Nel grafico della figura 6.2, è stata ottenuta la forma attesa delle linee arancione e verde. Man mano che il valore della probabilità restituito dal modello (asse X) aumenta, il numero di fumatori aumenta (linea arancione) e il numero di non fumatori diminuisce (linea verde). Se le linee fossero piatte per tutta la lunghezza (ancora intorno al 50%) o si intersecassero di tanto in tanto (una volta più alta la linea arancione e una volta più alta la linea verde), significherebbe che il modello non riesce a differenziare correttamente i fumatori e non funziona correttamente.

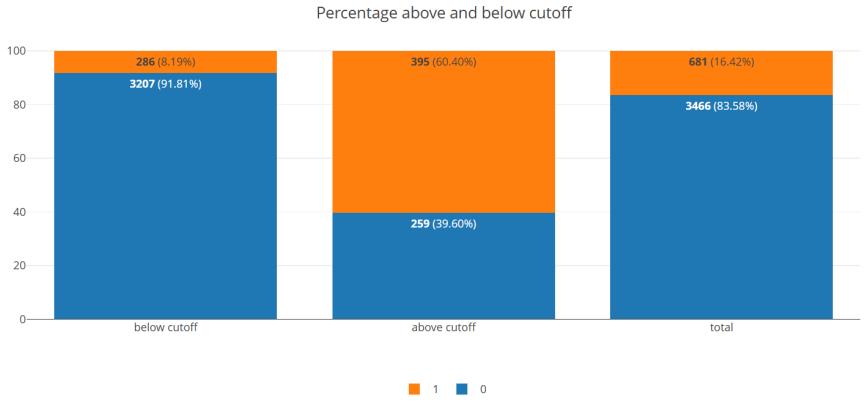


Figura 6.3: Classification Plot

Un modello perfettamente calibrato mostrerebbe una linea retta dall'angolo in basso a sinistra all'angolo in alto a destra. Un modello forte classificherebbe correttamente la maggior parte delle osservazioni e vicino al 0% o al 100% di probabilità.

Il grafico in figura 6.3 mostra la frazione di ciascuna classe sopra e sotto il probability threshold. Nella dashboard è presente uno slider in cui è possibile modificare il probability threshold e visualizzare come le persone passano da una classe all'altra in base a esso.

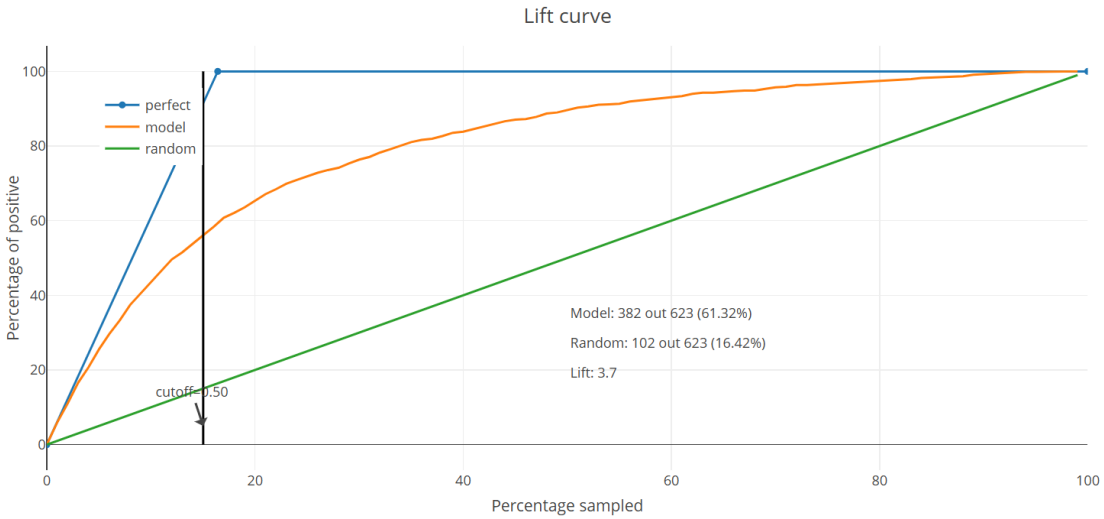


Figura 6.4: Lift Curve

Il grafico in figura 6.4 è una lift curve. Questo grafico mostra la percentuale delle classi positive quando si selezionano solo le osservazioni con un punteggio sopra il probabili-

ty threshold (o cutoff) rispetto alla selezione casuale delle osservazioni. Questo mostra quanto il modello sia migliore rispetto alla selezione casuale (il sollevamento).

6.1 | SHAP value

Dopo aver condotto un'analisi del modello mediante i grafici e acquisito una comprensione della sua affidabilità, abbiamo proposto di effettuare un'analisi finale al fine di esaminare le ragioni per le quali il modello risulta efficace e identificare le caratteristiche che maggiormente influenzano la probabilità di classificare un individuo come fumatore. A tale scopo, abbiamo scelto di utilizzare i valori **SHAP** (Shapley Additive Explanations).

I **valori SHAP** (Shapley Additive Explanations) costituiscono un approccio teorico e pratico per spiegare le previsioni dei modelli di apprendimento automatico, in particolare quelli basati su algoritmi complessi come gli alberi decisionali o le reti neurali. Derivati dalla teoria dei giochi, i valori SHAP forniscono una decomposizione degli output del modello in contributi attribuibili a ciascuna variabile di input, quantificando il contributo di ogni feature nell'effettuare una previsione specifica.

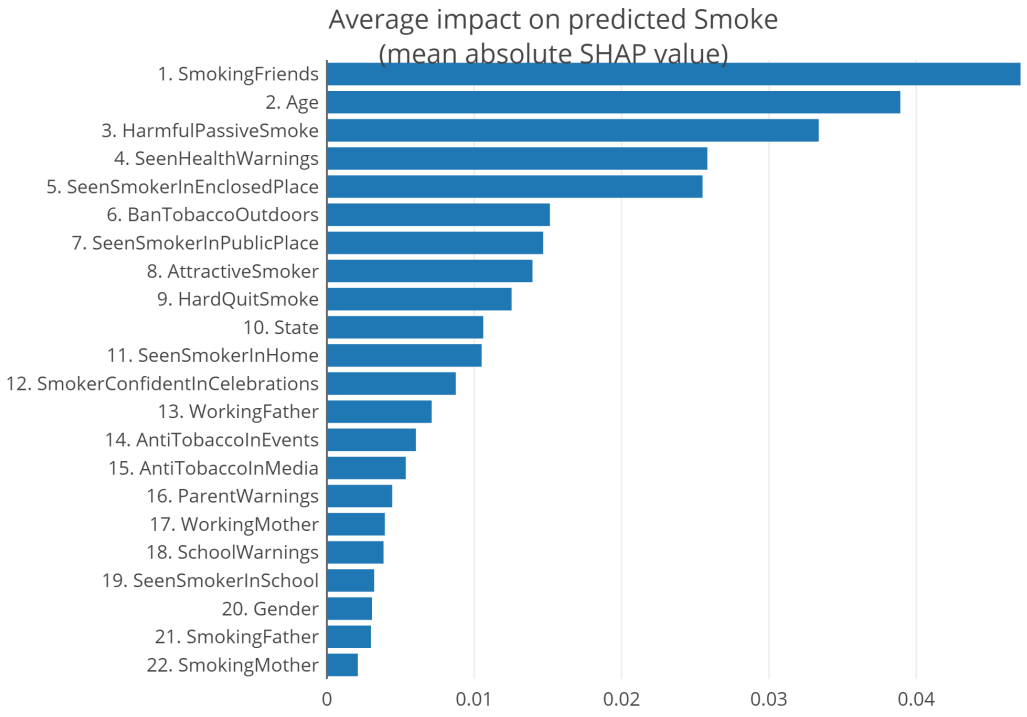


Figura 6.5: Feature Importance

I valori SHAP offrono una comprensione dettagliata del ruolo che ciascuna variabile gioca nel processo decisionale del modello, consentendo di identificare le caratteristiche più influenti e comprendere come influenzino le previsioni finali. Questo approccio è particolarmente utile per interpretare modelli complessi e supportare la validità delle decisioni prese dal modello stesso.

Nel grafico della figura 6.5 è presente la media del valore assoluto dei valori SHAP per ogni feature. Questo ci permette di capire quali sono le feature con più impatto nelle previsioni.

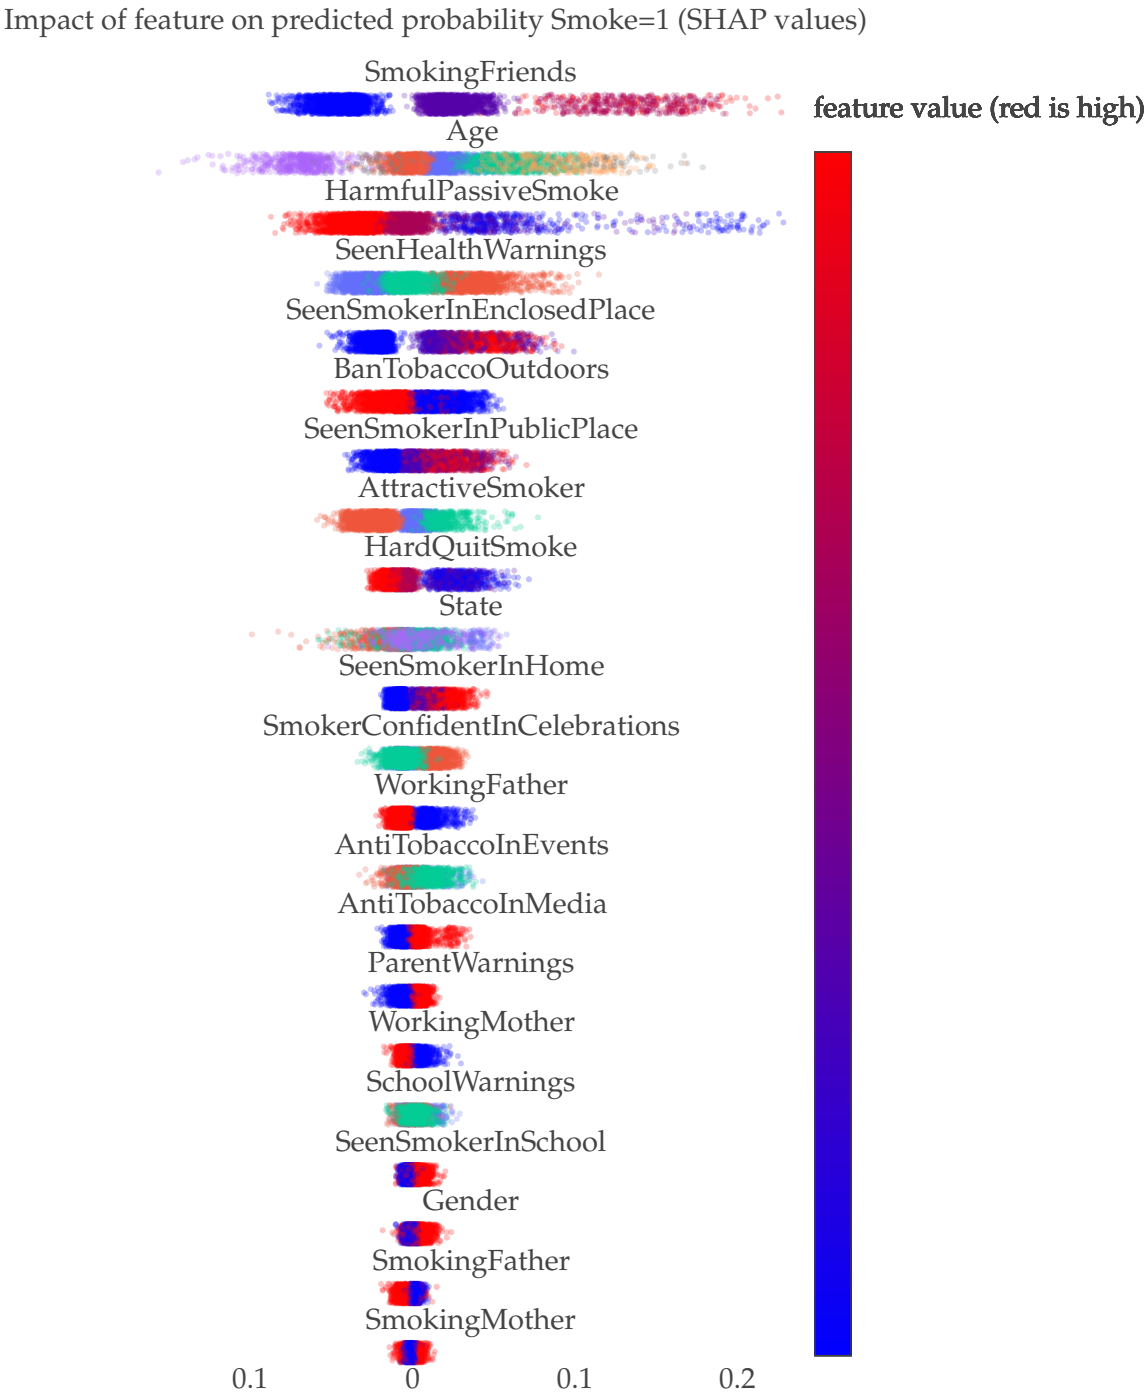


Figura 6.6: Feature importance dettagliata

La figura 6.6 rappresenta un diagramma in cui vengono plottati tutti gli SHAP value per ogni feature, a differenza del grafico precedente in cui venivano aggregati i valori SHAP di tutte le previsioni. Questo approccio è adottato al fine di ottenere una visualizzazione più approfondita della distribuzione dei valori SHAP relativi a ciascuna feature e della loro correlazione con i valori stessi delle feature.

Anche questo per questo grafico **è consigliato l'utilizzo della dashboard interattiva**, in quanto con essa è possibile analizzare ogni singola predizione all'interno del grafico.

I risultati dell'analisi indicano che diversi fattori hanno un impatto significativo sul consumo di tabacco tra giovani studenti. Tra questi, i fattori più rilevanti includono:

1. **Avere amici fumatori**: La presenza di amici che fumano emerge come uno dei fattori più importanti nell'influenzare il consumo di tabacco tra i giovani studenti. Gli studenti tendono ad essere influenzati dalle abitudini dei loro coetanei e possono essere più inclini a sperimentare il fumo se sono circondati da amici che lo praticano.
2. **Età**: L'età è un altro fattore chiave che influisce sul consumo di tabacco tra i giovani studenti. È noto che l'adolescenza è un periodo critico in cui molte persone iniziano a sperimentare con il fumo. I dati indicano che con l'aumentare dell'età aumenta la probabilità che gli studenti inizino a fumare o continuino il consumo di tabacco, spinti da una combinazione di fattori sociali, psicologici ed ambientali.
3. **Scarsa attenzione ai danni del fumo passivo**: Un'altra variabile significativa è la scarsa attenzione ai danni del fumo passivo. Gli studenti che non attribuiscono molta importanza ai rischi associati al fumo passivo possono essere più inclini a frequentare ambienti in cui si fuma e a sviluppare abitudini di consumo di tabacco.
4. **Frequenza di frequentazione di ambienti in cui si fuma**: Infine, la frequenza di frequentazione di ambienti (aperti o chiusi) in cui si fuma emerge come un altro fattore importante. Gli studenti che frequentano luoghi dove è comune il consumo di tabacco possono essere più esposti alla cultura del fumo e quindi più inclini a sviluppare abitudini di consumo di tabacco.

7 | Conclusioni

Da questa analisi si nota l'importanza di una comprensione approfondita dei fattori che influenzano il consumo di tabacco tra i giovani studenti. Dai risultati emerge chiaramente che il contesto sociale, l'età e la percezione dei rischi associati al fumo giocano un ruolo significativo nel determinare le abitudini tabagiche.

La presenza di **amici fumatori** risulta essere il **fattore più influente** nel determinare il comportamento dei giovani studenti, sottolineando l'importanza dell'influenza sociale sulle scelte individuali legate al tabagismo. Anche dalla letteratura emerge che la maggior parte degli studenti inizia a fumare a causa dell'influenza degli amici [1]. Come emerge dai nostri risultati e dalla letteratura, gli studenti che hanno più amici fumatori hanno maggiori probabilità di diventare fumatori [1]. Inoltre, iniziano a fumare per imitazione dei loro familiari fumatori e per curiosità.

Inoltre, l'**età** si conferma come un fattore determinante, poiché l'adolescenza rappresenta un periodo critico in cui si manifesta un'alta suscettibilità alle influenze esterne e si sviluppano abitudini di vita a lungo termine. La maggior parte dei fumatori a lungo termine infatti ha inizia a fumare dai 10 ai 25 anni [6]. Secondo Pierce et al. [1991], i giovani fumano per risolvere lo stress mentale e altri problemi emotivi. Pur sapendo che il tabacco crea una forte dipendenza, i giovani tendono a trascurare o a credere che non si ammaleranno mai di cancro ai polmoni o di problemi cardiaci perché sono relativamente giovani e sani.

La **scarsa attenzione ai danni del fumo passivo** emerge come ulteriore variabile significative, evidenziando l'importanza di educare gli studenti sui rischi per la salute associati al fumo, non solo attivo ma anche passivo.

Infine un ulteriore fattore che influenza i risultati è **l'esposizione al fumo**. I soggetti che per più tempo sono esposti al fumo, sono più probabilmente fumatori. Per questo una possibile soluzione potrebbe essere quella di proibire il fumo in luoghi pubblici. Infatti da altri studi [4] emerge che la proibizione del fumo nei luoghi pubblici riducono significativamente la frequenza del fumo nel tempo. Questa riduzione è associata a un calo del numero di persone che iniziano a fumare piuttosto che a un aumento del numero di persone che smettono di fumare. La riduzione è anche associata a una diminuzione della percentuale di fumatori abituali rispetto a quella dei non fumatori [2]. I divieti totali non hanno un impatto significativo sull'intensità del fumo, il che implica che i fumatori trovano altri luoghi e momenti per fumare [2]. Tuttavia, presentano benefici per i non

fumatori, in quanto sono associati a una diminuzione significativa dell'esposizione al fumo ambientale [2].

Come prospettive future per il progetto, si potrebbero considerare diversi sviluppi:

1. **Raffinamento del modello predittivo**: Le prestazioni del modello attuale potrebbero beneficiare di un ampio margine di miglioramento. In un contesto futuro, potrebbe essere opportuno esplorare l'inclusione di ulteriori feature rilevanti o l'adozione di metodologie differenti al fine di ottenere risultati più consistenti e affidabili.
2. **Validazione del modello mediante studi sul campo**: Una volta elaborato e validato, il modello predittivo potrebbe essere sottoposto a test sul campo. Questo potrebbe avvenire attraverso la conduzione di studi pilota presso istituti scolastici o centri giovanili, al fine di valutare l'efficacia del modello nell'identificare i giovani a rischio di iniziare a fumare tabacco. Tale approccio consentirebbe anche di valutare l'impatto di eventuali interventi preventivi basati sui risultati del modello, contribuendo così a informare politiche e programmi di salute pubblica mirati alla riduzione del consumo di tabacco tra i giovani.
3. **Studio dei fattori favorevoli alla cessazione del fumo**: Un'area di ricerca di notevole rilevanza potrebbe riguardare l'analisi dei fattori che facilitano la cessazione del fumo o l'evitamento del consumo di tabacco tra i giovani studenti. Identificare e comprendere tali variabili potrebbe fornire preziose informazioni per lo sviluppo di interventi mirati alla cessazione del tabagismo, con potenziali benefici significativi per la salute pubblica.

In conclusione, questa ricerca fornisce una base per futuri sforzi volti a contrastare il tabagismo giovanile e migliorare la salute e il benessere delle generazioni future. Speriamo che le informazioni e le raccomandazioni emerse da questo studio possano essere utilizzate per informare politiche e programmi efficaci nella lotta contro il tabagismo tra i giovani.

Bibliografia

[1] Md Sabbir Ahmed, Abu Sayeed, Ishrat Jahan, Md Forshed Dewan, and Sujan Kanti Mali. Prevalence and factors associated with cigarette smoking among resident university students: A crosssectional study from bangladesh. *Population Medicine*, 2 (February), 2020.

[2] Michael A Catalano and Donna B Gilleskie. Impacts of local public smoking bans on smoking behaviors and tobacco smoke exposure. *Health economics*, 30(8):1719–1744, 2021.

[3] Cheangaivendan Chezhian, Shruti Murthy, SatiSh PraSad, Jyoti Bala KaSav, Surapaneni Krishna Mohan, Sangeeta Sharma, Awnish Kumar Singh, and Ashish Joshi. Exploring factors that influence smoking initiation and cessation among current smokers. *Journal of clinical and diagnostic research: JCDR*, 9(5):LC08, 2015.

[4] JWKJW Kotrlik and HAWHA Williams. The incorporation of effect size in information technology, learning, information technology, learning, and performance research and performance research. *Information Technology, Learning, and Performance Journal*, 21(1):1, 2003.

[5] World Health Organization. Global youth tobacco survey. URL `https://www.who.int/teams/noncommunicable-diseases/surveillance/systems-tools/global-youth-tobacco-survey`.

[6] John P Pierce, Millie Naquin, Elizabeth Gilpin, Gary Giovino, Sherry Mills, and Steven Marcus. Smoking initiation in the united states: a role for worksite and college smoking bans. *JNCI: Journal of the National Cancer Institute*, 83(14):1009–1013, 1991.

[7] Robert West. Tobacco control: present and future. *British medical bulletin*, 77(1):123–136, 2006.